

Empresa: Hult International Business School
Cargo: Student Consultant – AI Policy/ AI in Education
Periodo: 08/2024 – 12/2024
Funciones principales: Co-diseñé la política y guías institucionales de IA académica para los programas UG legacy y UG renovado, alineándolas con los requisitos de acreditadores, profesorado, estudiantes y personal administrativo.

Yo, CAMILA ALEJANDRA CRUZ HERNANDEZ, certifico mi consentimiento del profesional en mención para incluir su hoja de vida en la propuesta del proceso No. CEL-CFU 02/26 denominada “SERVICIOS ESPECIALIZADOS PARA EL DESARROLLO DE UN PLAN PILOTO DE PRONÓSTICO HIDROLÓGICO AVANZADO BASADO EN INTELIGENCIA ARTIFICIAL”, y que dicho profesional ha declarado que estará disponible para realizar el trabajo de acuerdo con las disposiciones de ejecución y cronograma señalado en la propuesta.

f) Cronograma propuesto en el formulario

f.1) Estructura y planificación de la propuesta

N°	Producto Esperado o Entregable / Actividad	1	2	3	4	5	6	7	8	9	10	11	12
1	Entregable 1: Configuración de infraestructura y entorno	■											
	Actividad 1: Comisionamiento HW (solo IA)	■											
	Actividad 2: Red/Seguridad (VLAN / FW / VPN)	■											
	Actividad 3: Stack (Mage, PG/PostGIS, Mongo, Python)	■											
	Actividad 4: Validación / Benchmark (GPU / IO / Red)	■											
2	Producto 2: Adquisición y Pre-procesamiento de Datos		■	■									
	Actividad 1: Integración datos hidrológicos (aforos / dep.)		■										
	Actividad 2: Canal meteorológico (ERA5 / GPM / CHIRPS)		■	■									
	Actividad 3: Geoespacial (HydroATLAS / MDE / Suelos)				■								
	Actividad 4: QC + documentación (dataset listo)				■								

3	Producto 3: Configuración y Entrenamiento del Modelo	■	■	■
	Actividad 1: Implementación LSTM (NeuralHydrology)	■	■	
	Actividad 2: Optimización bayesiana (seq / hidden / LR)		■	■
	Actividad 3: Validación rolling-origin			■
	Actividad 4: Informe de desempeño			■
4	Producto 4: Operacionalización y Automatización			■ ■
	Actividad 1: Canalización diaria			■
	Actividad 2: Tableros web CEL		■	■
	Actividad 3: Alertas SMS / correo			■
	Actividad 4: Integración con sistemas / APIs			■
5	Producto 5: Validación del Piloto y Transferencia			■ ■
	Actividad 1: Pruebas OOS			■
	Actividad 2: Capacitación CEL			■
	Actividad 3: Documentación final			■

NOTA: Se hace constar que todo lo siguiente ya se encuentra desarrollado en el contenido de la Propuesta y en sus Anexos Técnicos: (i) la enumeración de entregables, con el detalle de actividades y metas —incluidas las aprobaciones del Contratante—; (ii) para trabajos en etapas y tareas en varias fases, la organización por etapa/fase con sus actividades, entregas de informes y metas correspondientes; (iii) el Plan de Trabajo para el desarrollo del contenido de los entregables, conforme al cronograma de ejecución; y (iv) la Matriz de Responsabilidades (RACI) de la consultoría, elaborada conforme a lo dispuesto en los Términos de Referencia y Condiciones de la Propuesta del DSP.

f.2) Plan de Trabajo para el desarrollo del contenido de los entregables

Favor encontrar esta información en los anexos. Para el presente apartado, se tuvo en consideración lo dispuesto en el Apartado I: Términos de Referencia y Condiciones de la Propuesta del DSP.

g) Matriz de responsabilidades de la consultoría (si aplica, sino eliminarlo)

Favor encontrar esta información en los anexos. Para el presente apartado, se tuvo en consideración lo dispuesto en el Apartado I: Términos de Referencia y Condiciones de la Propuesta del DSP.

SELECCIÓN DE FUENTE ÚNICA

REF.: No. CEL-CFU 02/26

PROPUESTA

**"SERVICIOS ESPECIALIZADOS PARA EL DESARROLLO
DE UN PLAN PILOTO DE PRONÓSTICO HIDROLÓGICO
AVANZADO BASADO EN INTELIGENCIA ARTIFICIAL"**

Jan 19, 2026

Indice

Indice.....	1
Propuesta de Implementación para la Comisión Ejecutiva Hidroeléctrica del Río Lempa (CEL).....	3
0. Configuración de Infraestructura y Entorno.....	5
1. Adquisición y Procesamiento de Datos.....	5
2. Desarrollo y Entrenamiento del Modelo.....	5
3. Integración Operativa.....	6
Anexo Técnico A: Sistema IA de Pronóstico Hidrológico para la Cuenca del Río Lempa.....	14
1. Flujo completo del sistema.....	14
2. Datos de entrada del sistema.....	16
3. Preprocesamiento y canalizaciones ETL: Orquestación de Datos y Pipelines con Python (Mage).....	18
4. Arquitectura y entrenamiento de los modelos de predicción.....	20
4.1 Modelo LSTM para predicción de caudales.....	21
4.2 Modelo de inundación (extensión de la anegación).....	22
5. Validación cruzada, métricas de evaluación y pruebas fuera de muestra.....	24
6. Infraestructura técnica y uso de recursos (GPU, entorno web y servicios externos).....	27
Arquitectura de Hardware Recomendada.....	27
Dimensionamiento de Cómputo y Almacenamiento.....	28
Entorno de desarrollo y lenguajes.....	28
Bases de datos y almacenamiento.....	29
Integración con servicios externos.....	29
7. Automatización y operación diaria del sistema.....	30
Programación de Ejecuciones.....	30
Flujo Diario de Ingesta y Pronóstico.....	30
Monitoreo y Gestión de Errores.....	31
Operación Continua y Ajustes.....	31
8. Visualización de resultados y sistema de alerta.....	32
Dashboard Web Interactivo (Node/React).....	32
Distribución de Alertas (Email/SMS).....	32
Integración y Adopción del Sistema.....	33
9. Consideraciones operativas específicas del Río Lempa.....	34
10. Recursos humanos y perfiles técnicos necesarios.....	36
Detalle de Tareas y Matriz de Roles (RACI).....	38
Tabla de tareas por fase del proyecto.....	38
Matriz RACI de Roles y Responsabilidades.....	39
Anexo Técnico B: Propuesta de Infraestructura Local para el Silo de IA de CEL.....	41
1. Contexto y Principios.....	42
2. Resumen de la Arquitectura Recomendada (Escenario 2, Revisado).....	42

3. ¿Cuántos datos moveremos realmente?.....	42
4. Dimensionamiento de Cómputo (GPU + RAM).....	43
5. Dimensionamiento de Almacenamiento.....	43
6. Consumo Energético y OPEX.....	44
7. Alineación Infra-Requisitos del Piloto.....	44
8. Coste Total de Propiedad.....	44
9. Conclusión.....	45
Anexo Técnico C: Lista de Materiales (BOM).....	45
1. Hardware e Infraestructura Propuesta.....	45
2. Software, Herramientas de Datos y Servicios.....	48
Anexo Técnico D: Riesgos Menores Identificados y Planes de Mitigación.....	50
Anexo Técnico E: Dinámicas Hidrológicas y Gobernanza Trinacional en la Cuenca del Río Lempa - Implicaciones para Modelos de Pronóstico con IA.....	51
1. Introducción.....	51
2. Características Geográficas e Hidrológicas.....	52
2.1 Origen y Trayecto.....	52
2.2 Zonificación Hidrológica.....	52
2.3 Puntos Críticos Hidrológicos.....	52
3. Riesgos e Impactos del Cambio Climático.....	53
3.1 Proyecciones Hidrológicas.....	53
3.2 Estacionalidad y Eventos Extremos.....	53
3.3 Dinámica de Sedimentos.....	53
4. Gobernanza Trinacional.....	53
4.1 Marco Institucional.....	53
4.2 Desafíos de Coordinación.....	54
4.3 Iniciativas en Curso.....	54
5. Implicaciones para el Sistema de Pronóstico con IA.....	54
5.1 Desafíos de Datos Transfronterizos.....	54
5.2 Variabilidad Hidrológica Espacial.....	54
5.3 Enfoque de Modelado Adaptativo.....	55
Referencias.....	56
Citations:.....	56

Propuesta de Implementación para la Comisión Ejecutiva Hidroeléctrica del Río Lempa (CEL)

Proyecto Piloto: Sistema Avanzado de Pronóstico Hidrológico

Resumen Ejecutivo

Esta propuesta detalla un plan integral para diseñar, construir y poner en operación un sistema avanzado de pronóstico de inundaciones impulsado por inteligencia artificial (IA) para el río Lempa. Aprovechando la metodología de Flood Hub de Google, revisada por pares y publicada en Nature, y empleando exclusivamente herramientas de código abierto, la iniciativa permite generar pronósticos probabilísticos a 7 días. El proyecto se fundamenta en la implementación de una **infraestructura de servidores on-premise nueva y dedicada**, la cual garantizará la soberanía y seguridad de los datos de CEL. El piloto concentra la inversión en talento especializado y en la creación de esta capacidad tecnológica, posicionando a CEL como líder regional en optimización hidroeléctrica basada en IA, gestión de inundaciones y toma de decisiones basada en datos.

Contexto del Proyecto y Valor Estratégico

Desafío	Impacto en las operaciones de CEL	Solución IA
Predicciones de caudal de embalse imprecisas	Despacho de generación subóptimo; mayor riesgo de vertido	Pronósticos basados en LSTM mejoran la precisión y elevan la eficiencia de generación 2–5 %¹¹
Limitado tiempo de antelación ante inundaciones	Gestión reactiva de compuertas; riesgo para comunidades	Pronósticos probabilísticos diarios a 7 días permiten liberaciones proactivas y alertas tempranas
Activos de datos dispersos	Información subutilizada; flujos de trabajo en silos	Lago de datos unificado y canalizaciones de ML convierten observaciones en inteligencia accionable

Actualmente, el 50% de las predicciones manuales se desvían más del 10% respecto al caudal real. Este error tiende a empeorar en caudales altos y presenta patrones persistentes, lo que confirma la necesidad de modelos automatizados basados en datos.

Objetivos del Proyecto

Este proyecto tiene como objetivo principal transformar la gestión de los recursos hídricos y la generación hidroeléctrica de CEL mediante la implementación de un sistema avanzado de pronóstico hidrológico basado en Inteligencia Artificial (IA) y la optimización de la operación de sus embalses y centrales hidroeléctricas en la cuenca del Río Lempa.

Los objetivos específicos son:

- **Mejorar la Precisión del Pronóstico de Caudales Afluentes:** Incrementar la precisión de los pronósticos de caudales de entrada a los embalses de CEL a un objetivo superior al 80% para horizontes de corto plazo (diario a 3 días), mediano plazo (1 semana) y dar soporte a la planificación de largo plazo (52 semanas).
- **Fortalecer la Toma de Decisiones Basada en Datos:** Transicionar de procesos de decisión predominantemente manuales e intuitivos a un enfoque sistemático y basado en datos, proporcionando herramientas de soporte a la decisión para los operadores y planificadores de CEL.
- **Incrementar la Resiliencia ante la Variabilidad Climática:** Dotar a CEL de herramientas avanzadas para anticipar y gestionar los impactos de la variabilidad y el cambio climático en los recursos hídricos de la cuenca del Río Lempa.

Diferenciadores Estratégicos

- **Metodología probada** – Basada en un referente global publicado en Nature^{10 12}.
- **Tecnología open-source** – Sin licencias, dependencia de proveedores ni compromisos en la nube.
- **Diseño escalable** – Arquitectura modular apta para integración y expansión a otros casos de uso futuros.
- **Desarrollo de capacidades** – Transfiere mejores prácticas de IA reproducibles al equipo técnico de CEL.

¿Por Qué Esto Es Relevante para CEL?

- **Planificación de Generación Mejorada:** Curvas de operación optimizadas aumentan la energía anual generada en 2–5 %¹¹.
- **Gestión de Influjos Mejorada** – Alertas más tempranas y fiables reducen costos de vertido de emergencia e impactos aguas abajo.
- **Reducción de Costos Operativos** – Programación y analítica impulsadas por IA reducen esfuerzos de campo y desperdicio de recursos 25–30 %¹¹.

- **Cultura Basada en Datos** – Integra analítica avanzada en los flujos diarios de despacho y mantenimiento.

Metodología de Implementación

0. Configuración de Infraestructura y Entorno

- Comisionamiento de Hardware: Implementación y configuración de la arquitectura de 3 nodos del silo de IA (ML/Compute, Data/ETL, Backup NAS).
- Configuración de Red y Seguridad: Establecimiento de la red aislada y el acceso remoto seguro (VPN).
- Instalación del Stack de Software: Despliegue de la plataforma de orquestación (Mage), bases de datos (PostgreSQL/PostGIS, MongoDB) y entornos de Python.

1. Adquisición y Procesamiento de Datos

- Integración Hidrológica: Ingesta automática de aforos de fuentes OSS; depuración y rellenado de lagunas históricas.
- Canalización Meteorológica: Descarga ERA5, GPM y CHIRPS; cálculo de precipitación, temperatura y ET.
- Procesamiento Geoespacial: Compilación de HydroATLAS, MDE (SRTM), cobertura de suelos; delimitación de cuenca y subcuencas.

2. Desarrollo y Entrenamiento del Modelo

- Framework: Implementación LSTM con NeuralHydrology en la GPU NVIDIA RTX 4090 (24 GB VRAM) del nuevo silo de IA.
- Optimización de Hiperparámetros: Búsqueda bayesiana sobre longitud de secuencia, unidades ocultas, tasa de aprendizaje.
- Validación: Validación con origen rodante; comparación con modelos de persistencia y conceptuales.

3. Integración Operativa

- Canalización diaria automatizada de pronósticos.
- Tableros y visualizaciones CEL.
- Alertas SMS/correo para umbrales críticos.

Ruta de Implementación y Entregables

Fase	Duración (semanas)	Tareas Clave	Entregable Principal
------	-----------------------	--------------	----------------------

0. Configuración de infraestructura y entorno	4	Comisionamiento de servidores, configuración de red, instalación de Mage y bases de datos.	Entorno "AI Silo" completamente operacional.
1. Adquisición y Pre-procesamiento de Datos	5	Fuentes, estandarización, control de calidad de datos hidrometeorológicos y geoespaciales	Conjunto de datos listo para análisis
2. Configuración y Entrenamiento del Modelo	9	Configurar LSTM; ingeniería de características; entrenamiento, ajuste y validación	Modelo validado de pronóstico hidrológico a 7 días
3. Operacionalización y Automatización	5	Construir canalizaciones en tiempo real; integración en BD; desarrollo del tablero web	Sistema automatizado de pronóstico end-to-end
4. Validación del Piloto y Transferencia de Conocimiento	5	Pruebas fuera de muestra; documentación técnica; sesiones de formación para el equipo CEL	Informe de validación piloto, POE y talleres internos
Total Estimado	28 semanas		Solución operativa de pronóstico de inundaciones basada en IA

Fase 0: Configuración de infraestructura y entorno

Esta fase inicial y fundamental establece la base tecnológica sobre la cual se construirá todo el proyecto. El éxito de las fases subsecuentes depende críticamente de un entorno de alto rendimiento, seguro y escalable, implementado desde el primer día. Esta etapa se enfoca en la creación de un "silo de IA" dedicado, asegurando que los recursos computacionales y de almacenamiento estén optimizados para las cargas de trabajo de machine learning y no compitan con otros sistemas de producción.

El objetivo principal en esta fase es implementar, configurar y validar la infraestructura de hardware y el stack de software completos que servirán como cimiento para el sistema de pronóstico. El objetivo final es entregar un entorno llave en mano, listo para el desarrollo.

Las actividades clave de esta fase incluyen:

- **Comisionamiento de Infraestructura Física:** En colaboración con el equipo de TI de CEL, supervisar la adquisición, instalación física (racking) y conexión eléctrica y de red de los 3 nodos de servidores especificados (ML/Compute, Data/ETL, Backup NAS). Se validará que cada componente cumpla con las especificaciones técnicas requeridas.
- **Configuración de Red y Seguridad:** Diseñar e implementar la arquitectura de red aislada para el "AI Silo". Esto incluye la configuración de VLANs, firewalls y políticas de acceso para garantizar la seguridad del entorno. Se trabajará estrechamente con el equipo de seguridad de CEL para configurar y validar el canal de acceso remoto seguro (VPN), permitiendo la colaboración y el desarrollo desde Boston.
- **Instalación y Configuración del Stack de Software:** Desplegar y configurar todo el software base. Esto abarca desde los sistemas operativos (Ubuntu Server LTS) hasta las bases de datos (PostgreSQL/PostGIS, MongoDB) y, crucialmente, la herramienta de orquestación de flujos de trabajo (Mage). Esta configuración incluye el establecimiento de las mejores prácticas para la gestión de dependencias y entornos virtuales de Python.
- **Validación y Pruebas de Esfuerzo (Benchmarking):** Ejecutar una serie de pruebas para certificar la estabilidad y el rendimiento del entorno. Se realizarán benchmarks de la GPU, pruebas de velocidad de E/S en los discos NVMe y SSD, y pruebas de conectividad de red entre los nodos y con las fuentes de datos externas.

Una vez concluida esta fase, el entregable principal será un documento de "Certificación de Entorno Operacional" que detalle la configuración final de hardware y software, los resultados de las pruebas de rendimiento y la confirmación de un acceso remoto seguro y funcional. Este entregable marca la conclusión exitosa de la fase y el inicio formal del desarrollo del piloto de IA.

Fase 1: Adquisición y Preprocesamiento de Datos

Es crucial recalcar que, para esta prueba piloto de replicación de la metodología, nos adherimos estrictamente a los datos utilizados inicialmente. El enfoque principal de esta etapa es lograr una replicación que establezca un nuevo baseline. Posteriormente, se explorará la posibilidad de aumentar este baseline con datos locales de CEL y procesarlos para que se conformen a los requerimientos de la metodología, con el objetivo de mejorar la precisión.

En este contexto, el rol crucial del equipo de CEL será interpretar esta nueva información de manera colaborativa, asegurando que los datos base para la replicación sean representativos de su ground-truth actual. Su participación activa en la evaluación y familiarización de los siguientes conjuntos de datos y procesos es fundamental:

- **Integración Hidrológica:** Se presentará y disponibilizará a los expertos en hidrología de CEL la información hidrológica que se descargará (ingesta automática de aforos, depuración y rellenado de lagunas históricas) para su evaluación y familiarización con el fin de replicar el proceso.
- **Canalización Meteorológica:** La información resultante de la descarga de datos ERA5, GPM y CHIRPS para el cálculo preciso de precipitación, temperatura y evapotranspiración (ET) se presentará y disponibilizará al equipo de CEL para su familiarización con el objetivo de replicar la metodología.
- **Procesamiento Geoespacial:** El equipo de CEL designará expertos en el área para la evaluación de los Modelos Digitales de Elevación (MDE) que se utilizarán (como SRTM) y en la ejecución de las compilaciones de información de HydroATLAS y datos de cobertura de suelos para la delimitación precisa de cuencas y subcuencas, con la meta de replicar el flujo de trabajo.

En esta fase inicial, el objetivo primordial es la replicación fiel de la metodología con los datos base. La interpretación colaborativa de CEL asegurará que este punto de partida refleje su conocimiento actual, sentando las bases para futuras optimizaciones.

Fase 2: Configuración y Entrenamiento del Modelo

Durante esta fase, la valiosa perspectiva del equipo de CEL será fundamental para asegurar la calidad y relevancia del modelo de pronóstico LSTM. Su participación se centrará principalmente en lo siguiente:

- **Validación de Patrones y Detección de Sesgos:** Su conocimiento profundo del comportamiento histórico del sistema hidrológico permitirá evaluar la validez de los patrones que el modelo aprenda de los datos, así como identificar posibles sesgos o inconsistencias que puedan surgir durante el entrenamiento.
- **Colaboración en el Ajuste de Hiperparámetros:** Su feedback será esencial para guiar el ajuste de los hiperparámetros del modelo. Al comprender las dinámicas del sistema, podrán ofrecer información valiosa para optimizar el rendimiento del modelo y su capacidad para generar pronósticos precisos en diversas situaciones.
- **Evaluación de la Capacidad de Pronóstico a 7 Días:** Su análisis de la capacidad del modelo entrenado para generar pronósticos precisos a 7 días será crucial. Su experiencia permitirá validar la coherencia y la confiabilidad de las predicciones, asegurando que se alineen con el comportamiento esperado del sistema hidrológico.

En resumen, en esta etapa, requeriremos principalmente que el equipo de CEL aporte su experiencia sustancial para validar los patrones aprendidos por el modelo, colaborar en el ajuste de sus parámetros y evaluar críticamente su capacidad de pronóstico a corto plazo. Esto asegurará que el modelo final sea robusto, preciso y confiable para sus necesidades operativas.

Fase 3: Operacionalización y Automatización

En esta etapa, nos enfocaremos en construir las canalizaciones en tiempo real necesarias para la operación continua del modelo y desarrollar una web app intuitiva y adaptada a las necesidades de CEL. Los componentes core de esta web app incluirán un panel de resumen de pronósticos clave, un mapa interactivo con gráficos de pronósticos temporales, así como filtros y toggles para interactuar con los diversos elementos de la interfaz.

Para asegurar que la web app sea lo más útil posible, requerimos la colaboración activa y la experiencia del equipo de CEL en los siguientes aspectos de alto nivel:

- **Identificación de Puntos de Interés:** Señalar las estaciones de aforo, áreas geográficas o umbrales críticos para su toma de decisiones.
- **Especificación de la Presentación de la Información:** Indicar cómo prefieren visualizar los datos del pronóstico (gráficos, tablas, indicadores), qué métricas son prioritarias y la representación deseada para alertas y umbrales.
- **Diseño de la Interfaz de Usuario:** Compartir sus preferencias sobre la disposición general de la interfaz, la navegación y la usabilidad para asegurar que sea intuitiva y eficiente.
- **Requerimientos de Interacción:** Describir las funcionalidades interactivas que necesitarían, como opciones de visualización, filtrado, selección de períodos de tiempo o exportación de datos.
- **Validación de la Información:** Participar en la revisión de la web app para asegurar que la información mostrada sea clara, precisa y coherente con su conocimiento del sistema hidrológico.

La experiencia de CEL sobre sus necesidades operativas será fundamental para guiar el diseño y la funcionalidad de la web app, asegurando que la herramienta final sea valiosa y se integre de manera efectiva en sus flujos de trabajo. Además de la colaboración en el diseño de la interfaz de la web app, requeriremos la asignación de personal y la disponibilidad de recursos de infraestructura por parte de CEL para asegurar el despliegue y funcionamiento del sistema automatiza

Fase 4: Validación del Piloto y Transferencia de Conocimiento

Esta fase se centrará en la rigurosa validación del sistema de pronóstico piloto y en la transferencia efectiva del conocimiento necesario para que el equipo de CEL pueda operar y mantener la solución a largo plazo.

Las actividades principales en esta etapa incluirán:

- **Pruebas Fuera de Muestra:** Realizaremos pruebas exhaustivas del modelo y la web app utilizando datos que no se utilizaron durante el entrenamiento ni la validación inicial. Esto permitirá evaluar la capacidad real del sistema para generalizar y generar pronósticos precisos en escenarios no vistos previamente. Analizaremos métricas clave

de rendimiento y compararemos los pronósticos del modelo con datos observados para cuantificar su precisión y confiabilidad.

- **Documentación Detallada:** Se elaborará una documentación completa y clara de todo el proceso, desde la ingesta y procesamiento de datos hasta la arquitectura del modelo, la implementación de la API y el funcionamiento de la web app. Esta documentación incluirá:
 - Un Informe Piloto que resuma los objetivos, la metodología, los resultados de la validación y las lecciones aprendidas durante todo el proyecto piloto.
 - Un Procedimiento Operacional Estándar (POE) detallado que describa paso a paso cómo operar el sistema de pronóstico, incluyendo la ejecución del modelo (si aplica), la gestión de la web app y la interpretación de los pronósticos.
 - Documentación técnica de la API, la estructura de la base de datos y cualquier otro componente técnico relevante para el mantenimiento y la posible expansión del sistema.
- **Capacitación del Equipo de CEL:** Se llevarán a cabo sesiones de formación personalizadas para el equipo de CEL. Estas sesiones cubrirán:
 - La comprensión general del modelo de pronóstico y sus limitaciones.
 - El uso detallado de la web app, incluyendo la navegación, la visualización de los pronósticos, la interpretación de las alertas y el uso de las funcionalidades interactivas.
 - Los procedimientos básicos para la operación y el monitoreo del sistema, siguiendo el POE.
 - Una introducción a la documentación técnica para aquellos miembros del equipo que puedan estar involucrados en el mantenimiento futuro.
- **Sesiones de Retroalimentación:** Fomentaremos sesiones interactivas con el equipo de CEL para recopilar su retroalimentación sobre la usabilidad de la web app, la claridad de la información proporcionada y su confianza en los pronósticos generados. Esta retroalimentación será invaluable para identificar áreas de mejora y asegurar la adopción exitosa de la solución.

El objetivo principal de esta fase es doble: primero, validar rigurosamente el sistema piloto para asegurar su precisión y confiabilidad en un contexto operativo real; y segundo, empoderar al equipo de CEL a través de la documentación y la capacitación para que puedan utilizar, mantener y potencialmente expandir la solución de pronóstico de manera autónoma en el futuro. Para llevar a cabo con éxito la Fase 4, requerimos la participación activa y la disponibilidad del equipo de CEL en los siguientes aspectos:

Disponibilidad para las Pruebas Fuera de Muestra: Necesitaremos su colaboración para identificar y proporcionar acceso a conjuntos de datos históricos relevantes que no se hayan utilizado previamente en el desarrollo y la validación del modelo. Su conocimiento de eventos pasados significativos (inundaciones, sequías, etc.) será crucial para seleccionar escenarios de prueba representativos. Además, requerimos su tiempo para revisar y validar los resultados de

los pronósticos generados durante estas pruebas, comparándolos con sus registros y experiencia.

- **Dedicación al Proceso de Documentación:** Si bien se elaborará la documentación, se requiere su tiempo para revisar el Procedimiento Operacional Estándar (POE) y el Informe Piloto. Su retroalimentación asegurará que la documentación sea clara, precisa y refleje fielmente sus procesos operativos y su comprensión del sistema.
- **Participación Activa en las Sesiones de Capacitación:** Será fundamental que los miembros clave del equipo de CEL asistan y participen activamente en las sesiones de formación. Su compromiso y preguntas durante estas sesiones asegurarán una comprensión profunda del sistema, la web app y los procedimientos operativos.
- **Disponibilidad para las Sesiones de Retroalimentación:** Requeriremos su tiempo y disposición para participar en las sesiones de retroalimentación. Sus comentarios honestos y constructivos sobre la usabilidad de la web app, la claridad de la información y su confianza en los pronósticos serán esenciales para identificar áreas de mejora y asegurar la adopción exitosa de la solución a largo plazo.
- **Identificación de Personal para el Mantenimiento Futuro:** Si bien la capacitación será general, agradeceríamos que CEL identifique a los miembros de su equipo que podrían estar más involucrados en el mantenimiento técnico futuro del sistema. Esto nos permitirá adaptar ligeramente la capacitación y la documentación técnica para satisfacer sus necesidades específicas.

En resumen, la colaboración activa, el tiempo dedicado y la retroalimentación honesta del equipo de CEL serán cruciales en esta fase para validar la efectividad del sistema y asegurar una transferencia de conocimiento exitosa que les permita operar y mantener la solución de pronóstico de manera autónoma.

Seguimiento y Comunicación del Proyecto

Para garantizar una comunicación fluida y mantener a todos los interesados informados sobre el progreso del proyecto, se implementará el siguiente esquema de seguimiento:

Presentación de Avances por Fase: Al finalizar cada una de las fases del proyecto, se llevará a cabo una sesión de presentación integral dirigida a todos los stakeholders pertinentes a esa etapa. En estas sesiones, se ofrecerá un resumen detallado de los avances logrados, los entregables completados y una visión completa de lo desarrollado hasta ese punto.

Sesiones de Avances Semanales (Core Team): De manera semanal, se realizará una sesión de sincronización con el equipo central del proyecto. Estas reuniones tendrán como objetivo revisar el progreso, discutir desafíos, coordinar tareas y asegurar que todos los miembros del equipo estén alineados y al tanto de las últimas novedades.

Interacciones Específicas por Etapa: Adicionalmente a las sesiones de sincronización semanales, se llevarán a cabo las interacciones y colaboraciones específicas detalladas en la

descripción de cada fase, involucrando a los miembros del equipo de CEL y otros stakeholders relevantes según las necesidades de cada etapa particular.

Este enfoque de comunicación estructurado asegurará que todos los stakeholders estén continuamente informados sobre el desarrollo del proyecto, facilitando la colaboración efectiva y la toma de decisiones oportunas en cada etapa.

Cronograma, Esfuerzo y Estimación de Costos

Fase	Horas Estimadas	Tarifa (USD/hr)	Costo (USD)	%
Configuración de infraestructura y entorno	114.8	250	28,700	14.00%
Adquisición y Pre-procesamiento de Datos	155.8	250	38,950	19.00%
Configuración y Entrenamiento del Modelo	246.0	250	61,500	30.00%
Operacionalización y Automatización	147.6	250	36,900	18.00%
Validación del Piloto y Transferencia	155.8	250	38,950	19.00%
TOTAL	820.0		205,000	100.00%

*La duración estimada del proyecto es de 28 semanas, con una carga aproximada de 30 horas semanales, derivado de la estimación total de 820 horas. *Los montos propuestos corresponden a honorarios profesionales.*

Oportunidad Estratégica para CEL

CEL se posiciona como la **pionera en la adopción de inteligencia artificial (IA) en el sector hidroeléctrico de Centroamérica**. Esta visión estratégica permite a CEL no solo optimizar sus

operaciones existentes, incrementando la eficiencia y reduciendo costos, sino también **establecer un nuevo estándar de gestión energética en la región.**

Al **incorporar soluciones de IA de estándar global**, CEL demuestra su compromiso con la innovación y la adopción de las mejores prácticas internacionales. Esta apuesta tecnológica se traduce en una mayor confiabilidad de la generación hidroeléctrica, una mejor planificación de recursos hídricos y la capacidad de anticipar y responder de manera proactiva a los desafíos operativos.

Con esta **ventaja de ser un adoptante temprano**, CEL está en una posición única para **influir en la evolución del sector energético en Latinoamérica**. Al mostrar los beneficios tangibles de la IA en la hidroelectricidad, CEL se proyecta como un **referente regional**, compartiendo su experiencia y contribuyendo al desarrollo de soluciones energéticas más inteligentes y sostenibles en toda la región.

Pasos Sigüientes Tras el Piloto

Fase	Cronograma Indicativo
II Mejora con Datos Locales	+4–6 meses
III Re-entrenamiento	*Se requiere 90 días post-entrega
IIII Integración Operativa Completa	+6–9 meses

Conclusión

El Piloto de Pronóstico de Inundaciones con IA para el río Lempa ofrece a CEL una puerta de entrada pragmática y respaldada científicamente hacia capacidades transformadoras de IA, con beneficios operativos, económicos y sociales tangibles. Al capitalizar activos computacionales existentes y recursos globales de datos abiertos, CEL puede disponer de un sistema de producción en seis meses, sentando las bases de una estrategia integral de optimización hidroeléctrica impulsada por IA.

Referencias

<https://ppl-ai-file-upload.s3.amazonaws.com/web/direct-files/attachments/11869384/feb37b96-52f3-4148-be4a-74fb4b58b096/paste.txt>

<https://ppl-ai-file-upload.s3.amazonaws.com/web/direct-files/attachments/11869384/a3ecc37c-50e1-4d32-bb9f-20b683f3cae9/paste-2.txt>

<https://blog.google/technology/ai/google-ai-global-flood-forecasting/>

<https://github.com/KMarkert/neuralhydrology-on-gcp>

<https://www.cobank.com/knowledge-exchange/power-energy-and-water/utilities-embrace-copiloting-with-artificial-intelligence-parachute-free>

<https://pmc.ncbi.nlm.nih.gov/articles/PMC11004570/>

<https://research.google/blog/using-ai-to-expand-global-access-to-reliable-flood-forecasts/>

<https://neuralhydrology.github.io/about/>

<https://hess.copernicus.org/articles/27/139/2023/>


Nearing, G. et al., Nature, 2024.

<https://research.ai-multiple.com/ai-utilities/>

<https://aiforgood.itu.int/flood-forecasting-at-google-the-ai-solution-for-global-impact/>

Anexo Técnico A: Sistema IA de Pronóstico Hidrológico para la Cuenca del Río Lempa

1. Flujo completo del sistema



Flujo propuesto del sistema desde la adquisición de datos hasta la emisión de alertas.

El sistema de pronóstico hidrológico basado en IA seguirá un **flujo de procesamiento de extremo a extremo**, desde la recopilación de datos hasta la generación de alertas tempranas de inundación. En términos generales, se compone de cuatro subsistemas principales – similares a los implementados por Google Flood Hub (Nevo et al., 2022)– integrados en la plataforma de CEL: **(1) Adquisición y validación de datos, (2) Pronóstico de caudales (modelo LSTM), (3) Modelado de inundación, y (4) Distribución de alertas (Nevo et al., 2022).**

Previo al inicio de este ciclo operativo, el proyecto arranca con una **Fase 0: Configuración de Infraestructura y Entorno**. Esta etapa inicial y fundamental se dedica a la construcción y comisionamiento de la infraestructura de servidores on-premise dedicada, la cual garantizará un entorno de alto rendimiento, seguro y escalable. La finalización exitosa de esta fase, que incluye la instalación del hardware y la configuración del stack de software, es el requisito indispensable para dar paso a la primera etapa operativa de ingesta de datos.

En la **primera etapa (Data Ingestion)**, se recopilan automáticamente datos meteorológicos, hidrológicos y geoespaciales de múltiples fuentes (detalladas en la siguiente sección) y se someten a controles de calidad y transformaciones necesarias. Estos datos crudos son ingeridos mediante procesos ETL (Extract-Transform-Load) orquestados con un framework moderno como Mage, que utiliza pipelines definidos en Python. Esta aproximación reemplaza a Pentaho PDI, mejorando la fiabilidad, el versionamiento y la mantenibilidad del código, a la vez que asegura una estandarización temporal y espacial robusta antes del almacenamiento en las bases de datos de CEL.

En la **segunda etapa (Pronóstico de caudales)**, el sistema utiliza modelos de redes neuronales recurrentes LSTM entrenados con datos históricos para pronosticar los caudales o niveles futuros en puntos clave del río (e.g. estaciones de aforo o “gauges” virtuales). El modelo LSTM procesa series temporales de precipitaciones pronosticadas y observadas, caudales recientes y otros atributos, para estimar el flujo de los próximos días (hasta un horizonte de 7 días). Este enfoque de aprendizaje automático ha demostrado mayor precisión que modelos lineales tradicionales, mejorando la capacidad de predicción de crecientes repentinas (Nevo et al., 2022).

La **tercera etapa (Modelado de inundación)** traduce las predicciones de caudal en información de áreas inundadas. Aquí se emplearán dos enfoques complementarios inspirados en Google Flood Hub (Nevo et al., 2022): (a) un **modelo de umbral** que, dado un caudal o nivel proyectado, calcula la extensión espacial de inundación esperada mediante mapas predefinidos y elevaciones críticas; y (b) un **modelo de inundación por “manifold” (aprendizaje automático avanzado)** capaz de estimar tanto la extensión como la profundidad de la inundación directamente a partir de las predicciones hidrológicas (Nevo et al., 2022). Ambos métodos serán entrenados y calibrados con datos locales y evaluados para asegurar su fiabilidad operacional.

Finalmente, en la **cuarta etapa (Alertas y visualización)**, los resultados se integran en un tablero web interactivo y se distribuyen notificaciones de alerta. El **dashboard** (desarrollado en la plataforma Node.js/React de CEL) mostrará en tiempo real los mapas de inundación previstos sobre una interfaz geográfica, así como las curvas de caudal pronosticado vs. umbrales de alerta en puntos de control. Si un pronóstico excede los niveles críticos predefinidos, el sistema activará **alertas automáticas** – por correo electrónico, SMS u otros canales – dirigidas a los responsables y comunidades pertinentes. Este esquema de notificación temprana permite acciones proactivas para mitigar el impacto de las crecidas. En síntesis, el flujo integral va **“de datos a decisión”**: captura datos brutos multisectoriales, los convierte mediante IA en pronósticos de caudal confiables, traduce esos pronósticos en zonas de inundación probables, y comunica oportunamente las alertas a quienes las necesitan.

2. Datos de entrada del sistema

El sistema aprovechará fuentes de datos heterogéneas – meteorológicas, hidrológicas, geoespaciales y de características de cuenca – para alimentar los modelos de pronóstico. A continuación, se detallan los insumos principales en cada categoría:

- **Datos meteorológicos:** Se utilizarán productos globales de prestigio para obtener precipitaciones y otras variables climáticas. En particular, se integrarán pronósticos numéricos del **modelo global ECMWF** (Centro Europeo) para horizontes de hasta 7 días, así como reanálisis históricos **ERA5** para series climáticas de largo plazo. Además, se incorporarán estimaciones satelitales de lluvia en tiempo casi real como **NASA GPM/IMERG**, que ofrecen cobertura global de precipitación por radar satelital con pocas horas de retraso. Estos datos proporcionan las **series de precipitación y temperatura** de entrada al modelo LSTM (Google Research & Cohen, 2024). Por ejemplo, el reanálisis ERA5-Land brinda datos consistentes de lluvia y temperatura desde 1980 a la fecha (Google Research & Cohen, 2024), útiles para entrenar el modelo, mientras que los pronósticos ECMWF e IMERG alimentarán la ejecución diaria para pronosticar caudales futuros. En caso necesario, se complementará con otras fuentes abiertas como **CHIRPS** (precipitación interpolada para Mesoamérica) para robustez en zonas con escasa cobertura de estaciones. Todo este conjunto meteorológico provee información redundante y robusta, reduciendo la incertidumbre de los pronósticos al combinar múltiples productos (Google Research & Cohen, 2024).
- **Datos hidrológicos:** Incluyen principalmente los **caudales observados** en el río Lempa y sus tributarios, que sirven para entrenar y calibrar el modelo de predicción. Se emplearán registros históricos de estaciones hidrométricas locales (p. ej., datos de CEL y autoridades hidro-meteorológicas de El Salvador, Guatemala y Honduras) y datos abiertos como la base global **GRDC** (Global Runoff Data Centre)(Google Research & Cohen, 2024). GRDC recopila series de caudal diarias de miles de ríos a nivel mundial, y contiene información que permitirá contrastar y extender los datos locales. Adicionalmente, el sistema está diseñado para generar **“gauges” virtuales**, es decir, puntos de pronóstico en ubicaciones donde no existe una estación física de medición (Google Research & Cohen, 2024). Estos gauges virtuales heredan conocimiento de la red hidrográfica y los patrones de lluvia para ofrecer estimaciones de nivel/caudal en sitios críticos (p. ej., desembocadura en el Bajo Lempa) aún sin sensores instalados. Si bien sus pronósticos no pueden validarse directamente por falta de observaciones, constituyen insumos valiosos para análisis en regiones sin cobertura gauge (Google Research & Cohen, 2024). En la operación diaria, también se incorporarán observaciones hidrológicas en tiempo real (donde existan) para actualizar el estado inicial del río y eventualmente realizar asimilación de datos que corrija desvíos del modelo con respecto a la realidad.
- **Datos geoespaciales:** Sirven tanto para caracterizar la cuenca en los modelos como para la etapa de inundación. Se utilizará un **Modelo Digital de Elevaciones (MDE)** de alta resolución – por ejemplo, SRTM de ~30 m o datos LiDAR locales si están disponibles –

para conocer la topografía detallada de la planicie de inundación. Este MDE permite delinear las zonas que quedarían bajo agua para un determinado nivel del río, por lo que es fundamental para el modelo de inundación basado en umbrales (identificando cotas críticas). Asimismo, se emplearán imágenes satelitales de **Sentinel-1 (radar SAR)** para obtener mapas históricos de inundaciones efectivas; el radar de apertura sintética detecta agua superficial aún bajo nubes, por lo que a partir de imágenes Sentinel-1 históricas se pueden derivar extensiones de inundaciones pasadas en el Bajo Lempa. Estas observaciones satelitales se usarán para calibrar y validar los modelos de inundación (e.g., ajustando el modelo para que reproduzca extents similares a las detectadas por SAR en eventos históricos). Adicionalmente, se aprovecharán datos de uso del suelo y cobertura terrestre (por ejemplo, CORINE Land Cover o mapas nacionales) para entender la interacción agua-terreno (p.ej., identificar áreas urbanas o agrícolas que puedan modificar la dinámica de escorrentía e inundación).

- **Características de la cuenca:** Se compilarán atributos fisiográficos e hidrológicos de la cuenca Lempa que enriquecen el modelo de IA. A través de recursos abiertos como **HydroATLAS/HydroSheds**, se obtendrán datos como: área de drenaje de subcuencas, elevación media, pendiente de laderas, tipo de suelo, parámetros climáticos medios, cobertura vegetal, entre otros (Google Research & Cohen, 2024). Estos rasgos estáticos se incorporan como *features* en el modelo LSTM para contextualizar el comportamiento hidrológico del Lempa frente a otras cuencas. En la metodología de Google, alimentar la red con atributos de cuenca le permitió generalizar a sitios no calibrados (Google Research & Cohen, 2024). En nuestro caso, dichos atributos ayudarán a **regionalizar** el modelo (por ejemplo, transfiriendo el aprendizaje desde cuencas similares hacia segmentos del Lempa con pocos datos locales) y a diferenciar el comportamiento de distintas subcuencas dentro del sistema. Por último, se delimitarán las sub-cuencas y áreas de aporte principales (p. ej., cuenca alta en Guatemala, cuenca media con embalses, cuenca baja en El Salvador) usando herramientas GIS sobre el MDE, para asociar los datos meteorológicos espacialmente a cada región hidrológica relevante.

En síntesis, el sistema manejará un volumen significativo de datos de entradas diversas. Todas las fuentes mencionadas son **abiertas o de acceso público**, evitando costos de licenciamiento. La combinación de múltiples insumos meteorológicos y la inclusión de datos geoespaciales enriquecen la **robustez del pronóstico**, permitiendo al modelo LSTM aprender de la lluvia y caudales históricos, y al componente de inundación disponer de mapas base precisos para delinear las alertas.

3. Preprocesamiento y canalizaciones ETL: Orquestación de Datos y Pipelines con Python (Mage)

Para convertir los datos brutos de múltiples orígenes en insumos listos para la modelación, se implementará una robusta canalización de datos utilizando un framework moderno de orquestación basado en Python, como **Mage**. Esta decisión estratégica reemplaza el uso de Pentaho PDI para este proyecto, con el fin de mejorar la fiabilidad, la observabilidad y, fundamentalmente, la capacidad de versionamiento del código de los flujos de trabajo, abordando directamente las limitaciones operativas identificadas. La definición de los pipelines como "código" permite una integración nativa con sistemas de control de versiones (Git) y facilita la automatización, el mantenimiento y la escalabilidad a largo plazo.

Esta metodología moderna se conecta con los sistemas existentes de CEL de forma segura y estándar. El nuevo "Nodo de Datos & ETL" actuará como un cliente dentro de la red de CEL, utilizando conectores de base de datos para consultar (en modo de solo lectura) la información de los servidores PostgreSQL y MongoDB existentes. Todo el procesamiento y la transformación de datos se ejecutarán en el nuevo hardware dedicado, asegurando que los sistemas originales no se vean sobrecargados y que la soberanía de los datos se mantenga en todo momento.

El preprocesamiento abarcará las siguientes etapas, ejecutadas como código Python orquestado por Mage:

- **Extracción automática de datos:** Se desarrollarán scripts en Python dentro de Mage para conectarse de forma programada y automática a las diversas fuentes de datos. Esto incluye el consumo de APIs para datos meteorológicos (e.g., archivos GRIB/NetCDF de ECMWF) y la descarga de imágenes satelitales (GPM, Sentinel-1) utilizando librerías como **requests**. Asimismo, se automatizará la extracción de datos hidrológicos de los sistemas de CEL, conectándose a las bases de datos existentes mediante conectores específicos como **psycopg2** para PostgreSQL y **pymongo** para MongoDB. Los datos crudos se cargarán en un área de "staging" dentro de las nuevas bases de datos del silo de IA para su posterior transformación.
- **Transformación y limpieza:** Una vez obtenidos, los datos pasan por etapas de **data cleaning** y reformato utilizando el poder del ecosistema de Python, principalmente con librerías como **Pandas**, **GeoPandas** y **NumPy**. Estas transformaciones incluirán:
 - **Conversión y Homogeneización:** Convertir unidades (p. ej. de mm a m³/s), estandarizar zonas horarias y referencias temporales (crítico al combinar pronósticos y observaciones), y re-muestrear series temporales a un paso común (diario) utilizando las capacidades de manipulación de series de tiempo de Pandas. Se aplicará relleno de lagunas (**gap-filling**) en series históricas usando métodos apropiados (interpolación lineal, media estacional, etc.).
 - **Procesamiento Geoespacial:** Para datos meteorológicos en formato ráster, se ejecutarán transformaciones geoespaciales con librerías como **rasterio** y **geopandas**. Se calculará la precipitación media areal sobre la cuenca o subcuencas del Lempa superponiendo las máscaras de cuenca (derivadas del

MDE) sobre los campos de lluvia diarios de ERA5/GPM. De igual forma, en el caso de imágenes Sentinel-1 para inundaciones, el preprocesamiento implica aplicar algoritmos de clasificación de agua (p.ej., umbral de backscatter) para derivar polígonos de áreas inundadas históricamente, los cuales luego se almacenan como capas vectoriales.

- **Ingeniería de Características:** Se crearán variables adicionales para el modelo, como indicadores temporales (día del año) o el cálculo de la evapotranspiración potencial (ET) con fórmulas empíricas.
- **Carga en las bases de datos:** Tras la transformación, los resultados se cargan (**Load**) en los repositorios de datos dedicados del silo de IA. Conforme a la arquitectura definida, se distinguirán dos destinos:
 - Una base **NoSQL MongoDB** alojará los datos operativos de tiempo real, como las últimas mediciones de lluvia, caudales recientes y las predicciones diarias generadas. MongoDB es idónea para almacenar documentos JSON con estructuras flexibles, permitiendo que el frontend (Node.js/React) consulte rápidamente el estado más reciente.
 - La base relacional **PostgreSQL**, extendida con **PostGIS** para datos geoespaciales, almacenará los datos históricos depurados y las capas estáticas. Las series largas de precipitación y caudal se guardarán en tablas históricas para análisis y re-entrenamiento, mientras que las geometrías de la cuenca y los mapas de inundación se almacenarán como tipos de datos espaciales.

Durante todo el proceso, se implementarán controles de calidad automáticos (QA/QC). Cada script de Python incluirá aserciones y rutinas de validación para verificar la consistencia de los datos (e.g., que el caudal no sea negativo, que los acumulados de lluvia estén dentro de rangos esperados). La interfaz de Mage proporcionará un monitoreo detallado del estado de cada ejecución, con registros (logs) y notificaciones de error, garantizando que solo datos confiables alimenten a los modelos de IA.

En resumen, mediante el uso de Mage y el ecosistema de Python, el sistema realizará una canalización de datos moderna, robusta y reproducible. Esta aproximación no solo se integra de forma segura con la infraestructura existente de CEL, sino que también establece una base sólida para el futuro, minimizando la necesidad de nuevas plataformas y promoviendo las mejores prácticas de ingeniería de datos. Al final de esta etapa, dispondremos de un "lago de datos" unificado y listo para alimentar los algoritmos de predicción y visualización operacional.

4. Arquitectura y entrenamiento de los modelos de predicción

En esta sección se documenta la metodología de modelado basada en redes neuronales para pronosticar los caudales del río Lempa y derivar las áreas inundadas correspondientes. El enfoque principal consiste en emplear **redes LSTM (Long Short-Term Memory)** para el pronóstico hidrológico, complementadas por modelos de inundación que traduzcan esos

resultados a impactos geoespaciales. A continuación, se detalla la arquitectura de estos modelos y el plan de entrenamiento:

4.1 Modelo LSTM para predicción de caudales

El modelo hidrológico se basa en una red neuronal recurrente tipo **LSTM**, elegida por su eficacia en capturar dependencias temporales a largo plazo en series hidrológicas (precipitación-escorrentía). Estudios previos han demostrado que las LSTM superan a modelos hidrológicos conceptuales calibrados tradicionalmente, incluso al generalizar a cuencas no usadas en entrenamiento. Para la cuenca del Lempa, se implementará un **LSTM multivariable** capaz de ingerir las secuencias temporales de entrada (precipitaciones, temperaturas y caudales recientes) y producir como salida la serie pronosticada de caudales para los próximos días. En concreto, el LSTM tomará como *features* por cada paso de tiempo: (i) precipitaciones diarias acumuladas sobre la cuenca (y potencialmente otras variables climatológicas como temperatura media), (ii) caudal/nivel del río en el día actual (autoregresión, si datos disponibles), y (iii) indicadores temporales (p. ej., día del año para capturar estacionalidad). Adicionalmente, se incorporan **atributos estáticos de la cuenca** – como área de drenaje, pendiente media, uso del suelo – que se concatenan o usan para inicializar el estado oculto de la red, tal como sugiere la literatura (Google Research & Cohen, 2024). Esto permite al modelo “conocer” las características físicas del Río Lempa (y de sub-cuencas) que modulan su respuesta hidrológica, mejorando la generalización espacial del pronóstico.

La arquitectura detallada del LSTM consistirá en una o más capas LSTM con un cierto número de **neuronas ocultas** (hiperparámetro a definir), seguidas de capas densas que generan la salida deseada. Posiblemente se utilice un esquema *sequence-to-sequence*, donde la red procesa una secuencia de entrada (ej. últimos N días) y emite una secuencia de salida (próximos 7 días de caudal). Alternativamente, se puede entrenar para predecir un día por vez y encadenar predicciones, aunque el primer enfoque suele ser más eficiente. El tamaño de la ventana de entrada (N días usados para predecir) y la profundidad de la red se determinarán mediante experimentación.

Para construir este modelo de forma eficiente, se adoptará un **framework de código abierto especializado en hidrología**. En particular, se propone emplear la librería **NeuralHydrology** (desarrollada por Kratzert et al.), que proporciona implementaciones estándar de LSTM para pronóstico de caudal (Nearing et al., 2024). NeuralHydrology facilita la definición de arquitecturas, lectura de datos hidroclimáticos y cálculo de métricas, acelerando el desarrollo y asegurando reproducibilidad. El componente central para el cómputo acelerado será la GPU NVIDIA RTX 4090 (24 GB VRAM), especificada como parte integral de la arquitectura recomendada para el nuevo silo de IA, se entrenará el modelo con PyTorch/NeuralHydrology, beneficiándose del paralelismo de la GPU para manejar grandes volúmenes de datos en menos tiempo.

El **entrenamiento** se realizará usando los datos históricos integrados: varios años de registros diarios de lluvia y caudal, asegurando incluir una diversidad de eventos (temporada seca, lluvias extremas, paso de huracanes, operación de embalses, etc.). Se dividirán los datos en períodos de entrenamiento, validación y prueba, respetando la secuencia temporal para evitar filtraciones del futuro (p. ej., usando validación con origen rodante, descrita más adelante). La función de pérdida primaria puede ser el error cuadrático medio (MSE) entre caudal pronosticado y observado, aunque se evaluarán también métricas hidrológicas como el coeficiente de Nash-Sutcliffe (NSE) durante la validación. Dado que se buscan **pronósticos probabilísticos** a 7 días, se explorará entrenar la red no solo para un valor medio sino para distribuir resultados (p. ej., mediante ensambles con perturbaciones de entrada o incorporando la dispersión de pronósticos meteorológicos). No obstante, inicialmente el foco estará en obtener el mejor pronóstico determinista posible.

Ajuste de hiperparámetros: Para optimizar el rendimiento del LSTM, se implementará una búsqueda automatizada de hiperparámetros, idealmente mediante métodos eficientes como la **búsqueda Bayesiana**. Aspectos a calibrar incluyen: el número de unidades ocultas en la(s) capa(s) LSTM, la longitud de secuencia de entrada (ventana temporal de días), la tasa de aprendizaje y regularización, etc. Se aprovecharán frameworks de optimización (por ejemplo Optuna) que integran con PyTorch para explorar sistemáticamente las combinaciones. La propuesta es realizar decenas de corridas de prueba para converger en la configuración óptima, considerando la capacidad computacional disponible. Esta práctica, mencionada también en la planificación original, busca maximizar la precisión del modelo antes de su despliegue operativo.

Tras entrenar el modelo LSTM, se obtendrá un **modelo validado de pronóstico a 7 días** (como se detalla en la sección de validación) capaz de generalizar razonablemente a situaciones fuera de lo visto. Cabe destacar que la red LSTM, al estar entrenada con datos históricos incluyendo la influencia de embalses, aprenderá implícitamente ese comportamiento. No obstante, se considerará integrar reglas adicionales o inputs específicos para representar la operación de embalses (por ejemplo, incluir el nivel del embalse como entrada si se dispone, o segmentar el río en dos tramos: arriba y abajo de la presa principal). En todo caso, el modelo LSTM constituirá el **núcleo predictivo hidrológico** del sistema, entregando diariamente pronósticos de caudal/escenario que alimentarán la siguiente etapa.

4.2 Modelo de inundación (extensión de la anegación)

Este componente toma las salidas del modelo hidrológico (caudales o niveles pronosticados) y estima qué áreas geográficas serían afectadas por inundaciones bajo esos escenarios. Se implementarán dos enfoques complementarios, siguiendo la metodología de Google Flood Hub (Nevo et al., 2022), para asegurar precisión y rapidez:

- **Modelo de Umbral (Thresholding):** Consiste en un método basado en reglas fijas que relaciona un nivel de río con una extensión de inundación predefinida. En la práctica, se

elaborarán **mapas de inundación para niveles umbral** mediante análisis geoespacial: por ejemplo, usando el MDE se puede determinar qué áreas del Bajo Lempa quedan bajo agua cuando el río alcanza cierto nivel (ej. 5 metros en la estación X). Estos mapas umbral pueden provenir de simulaciones hidráulicas estáticas o de observaciones históricas (p. ej., el área máxima inundada observada en la tormenta Stan podría asociarse al caudal pico medido de 3000 m³/s). Una vez preparados estos escenarios, el modelo en sí es simple: **si el pronóstico de caudal/nivel excede un umbral crítico**, se activa la correspondiente capa de inundación. Por ejemplo: *“Si caudal pronosticado en San Marcos > 2500 m³/s, entonces inundar polígono de zona baja en San Vicente”*. Este modelo es computacionalmente ligero y garantiza que ante condiciones extremas el sistema muestre inmediatamente la zona potencial de impacto. Se pueden definir varios umbrales (alerta verde, amarilla, roja) con mapas incrementales de área inundada. La calibración de estos umbrales se hará combinando conocimiento de expertos locales y análisis de imágenes satelitales de eventos pasados. Aunque es un método simplificado (no modela hidráulica en tiempo real), en operaciones globales ha demostrado desempeño suficiente para extensión de inundaciones (Nevo et al., 2022), y sirve como baseline inmediato mientras se desarrolla el modelo más complejo.

- **Modelo de Inundación por Manifold (ML avanzado):** Es un modelo de aprendizaje automático que busca aproximar el comportamiento de un modelo hidráulico 2D sin necesidad de resolver explícitamente las ecuaciones de flujo. El concepto presentado por Google es construir un espacio latente (*manifold*) de posibles configuraciones de inundación, y entrenar un modelo (p. ej. una red neuronal) que mapee las condiciones hidrológicas de entrada a ese espacio latente, generando como salida la inundación prevista (tanto extensión como potencialmente profundidad). En términos prácticos, emprenderemos el desarrollo de un modelo ML que tome como entrada variables como: caudal pico pronosticado, volumen excedente esperado, estado del suelo previo (proxy de saturación) y quizá otros (como indicadores de pendiente del terreno, ancho del valle, etc.), y produzca como salida una **máscara de áreas inundadas** (por ejemplo, en una grilla binaria de alta resolución marcando inundado/no-inundado, o una lista de polígonos inundados con sus profundidades promedio). Para entrenar este modelo, se requiere un conjunto de “verdades terreno” de inundación para diversos eventos. Estas verdades se obtendrán de **imágenes Sentinel-1 históricas clasificadas** y/o simulaciones hidráulicas de eventos extremos. Por ejemplo, se puede alimentar al modelo con datos de varias tormentas (precipitación y caudales medidos) junto con el mapa de inundación observado en cada caso, para que aprenda la relación no lineal entre la magnitud del evento y las áreas afectadas. Dado el limitado número de eventos extremos registrados, es probable que se use **transfer learning** desde datos sintéticos: generar múltiples escenarios mediante un modelo hidráulico (p. ej., HEC-RAS 2D) alterando caudales pico y condiciones, para crear un banco de mapas de inundación simulados. Estos mapas, reducidos dimensionalmente (de ahí el término manifold), servirían para entrenar una red (posiblemente un modelo tipo autoencoder o una CNN)

que reconozca patrones de inundación.

En la fase operativa, el modelo manifold recibiría el pronóstico específico (por ejemplo: “crecida de 1000 m³/s con suelos saturados”) y produciría rápidamente el mapa de inundación asociado, mucho más rápido que correr un modelo físico en tiempo real. Si bien este enfoque es complejo, la investigación indica que puede lograr precisión similar a la de modelos hidráulicos tradicionales (Nevo et al., 2022). En nuestro piloto, buscaremos implementar una versión simplificada de este concepto: inicialmente, generar mapas de profundidad para casos de diseño (5, 10, 50 años de período de retorno) y entrenar quizás un modelo de regresión o árbol de decisión que seleccione/extrapole entre esos mapas según el caudal pronosticado. A medida que se recopilen más datos de inundaciones observadas, se podrá ir refinando hacia la solución completa de manifold ML.

Tanto el modelo de umbral como el de manifold serán validados frente a datos históricos. Se espera que sus desempeños sean similares en cuanto a acierto en extensión inundada (Nevo et al., 2022), con la diferencia de que el modelo ML puede también dar **profundidades** estimadas en cada punto (valor agregado importante para evaluación de daños). Para no introducir riesgos, inicialmente se podría operar con el modelo de umbral (más interpretable) y usar el modelo ML en paralelo para evaluación interna hasta asegurarnos de su confiabilidad. Una vez listo, el modelo de inundación ML proveerá mapas más detallados y adaptativos.

Integración con el LSTM: Es importante resaltar cómo se acoplarán ambos modelos. El LSTM proveerá un **hidrograma pronosticado** (caudal vs. tiempo) en ciertos puntos de control (p.ej., salida de embalses, entrada de zonas críticas). De ese hidrograma, el sistema extraerá los valores relevantes para inundación, típicamente el **caudal pico previsto** y su **timing**. Esos valores se introducirán al modelo de inundación: en el caso del umbral, se comparan con los umbrales definidos; en el caso del ML manifold, se escalan las entradas del modelo. Adicionalmente, podría incorporarse la **duración esperada** de caudales altos, ya que inundaciones prolongadas afectan áreas más extensas (p. ej. saturan humedales). El modelo manifold puede aceptar esto de forma natural si se incluye el volumen o duración como input. Toda esta arquitectura modelo-compuesto (LSTM + inundación) será implementada de manera modular para facilitar ajustes.

En suma, la combinación de un **modelo LSTM** para pronosticar el comportamiento hidrológico y un **modelo de inundación** para traducirlo en impactos territoriales, replica la metodología de Google adaptada al contexto local. Esta dupla proporcionará tanto **pronósticos numéricos** (caudales, niveles) como **productos geoespaciales** (mapas de riesgo) en un flujo unificado.

5. Validación cruzada, métricas de evaluación y pruebas fuera de muestra

La validación rigurosa del sistema es crucial para garantizar confianza en sus pronósticos. Se implementará un esquema de **validación cruzada temporal** y evaluación con métricas especializadas, incluyendo pruebas fuera de muestra que emulen condiciones reales no vistas durante el entrenamiento.

Validación del modelo LSTM (caudal): Dado que los datos temporales no son independientes, se usará una estrategia de **validación con origen rodante (rolling origin)**. Esto implica dividir la serie histórica en múltiples segmentos cronológicos: por ejemplo, entrenar el modelo con datos hasta el año X y validar pronosticando el año X+1; luego ampliar la ventana y repetir. Así se generan varios *folds* de validación secuencial que prueban el modelo en periodos posteriores no usados en el ajuste de parámetros. Esto imita la situación de pronosticar el futuro con solo datos del pasado. Cada iteración de validación proporcionará métricas de desempeño (error, NSE, etc.) que luego se promedian para estimar la capacidad predictiva robusta del LSTM. Adicionalmente, se reservará **un conjunto de prueba final (out-of-sample)** – idealmente los eventos más recientes o significativos no incluidos en ningún entrenamiento – para hacer una **prueba ciega** del sistema completo al final. Por ejemplo, podríamos apartar datos de los últimos 1-2 años (o de un evento extremo específico) y usarlos solo al final para verificar cómo el modelo pronostica algo que nunca “vio”.

Las **métricas de evaluación** para caudal incluirán:

- **Coefficiente Nash-Sutcliffe (NSE):** mide la eficiencia del pronóstico respecto a la media observada (NSE=1 es perfecto, NSE=0 equivale a usar la media histórica). Es una métrica estándar en hidrología para caudal (Nevo et al., 2022).
- **RMSE y MAE:** el error cuadrático medio y el error absoluto medio, en unidades de caudal (m^3/s), para cuantificar la desviación típica de las predicciones.
- **Coefficiente de determinación (R^2):** para evaluar la correlación entre predicho y observado.
- **Skill score vs. persistencia:** compararemos el modelo contra una línea base trivial (por ejemplo, “pronóstico igual al valor de ayer” – persistencia). Se puede calcular un NSE de persistencia o simplemente indicar cuánto porcentaje mejora el RMSE respecto a asumir caudal constante (Nevo et al., 2022). Esto demuestra el valor añadido de la IA.
- **Detección de crecidas (POD/FAR):** en contexto de alertas, evaluaremos si el modelo acierta la ocurrencia de eventos de creciente. Se definirán umbrales de caudal para eventos de inundación y se calculará la **probabilidad de detección (POD)** – porcentaje de eventos de inundación observados que fueron pronosticados correctamente – y la **tasa de falsas alarmas (FAR)** – porcentaje de alertas emitidas que no se materializaron. Un buen sistema debe lograr POD alto con FAR bajo, optimizando ambos. Estas

métricas se pueden extraer de la serie de pronósticos comparada con registros de inundaciones históricas.

Durante la validación, se generarán gráficos comparativos de hidrogramas pronosticados vs observados para eventos pasados importantes (p. ej., crecidas por tormentas tropicales). Así, visualmente se evaluará si el modelo anticipa bien el pico (timing y magnitud) y el volumen total. Se ajustarán parámetros si se ve sesgo sistemático (por ejemplo, si siempre subestima picos altos, podría mejorarse la representación de precipitación extrema o añadir algún factor de corrección).

Validación del modelo de inundación: Este aspecto requiere comparar las áreas inundadas pronosticadas con registros de inundaciones reales. Se dispone de varios mecanismos: imágenes satelitales históricas (Sentinel-1, Landsat) con las que se puede reconstruir la huella de inundación de ciertos eventos, reportes de campo y mapas de entidades de protección civil del “Bajo Lempa” para inundaciones pasadas, y/o resultados de modelos hidráulicos de referencia. Para evaluar el desempeño, se emplearán métricas espaciales como:

- **Índice de Jaccard (Intersection over Union):** proporción de área donde pronóstico y realidad coinciden dividido entre el área total bajo al menos uno de ellos. Un valor 1 indica coincidencia perfecta del polígono inundado.
- **Tasa de omisión y comisión:** porcentaje de área inundada real que **no** fue predicha (omisiones), y porcentaje de área predicha que en realidad no se inundó (comisión). Estas métricas complementan la percepción de falsos negativos/positivos espaciales.
- **Distribución de profundidades (si aplica):** si el modelo produce profundidades estimadas, se puede comparar la estadística de esas profundidades con mediciones puntuales o con niveles históricos. Por ejemplo, verificar si predijo ~0.5 m en tal comunidad cuando se reportó ~0.4-0.6 m en realidad.

Debido a la escasez de datos extensivos de validación para inundación (especialmente en cuencas no instrumentadas), adoptaremos también la técnica usada por Google: **validación indirecta por eventos detectados en SAR** (Google Research & Cohen, 2024). Es decir, corroborar que **cuando el modelo pronostica una inundación, exista evidencia satelital de anegamiento**, y viceversa (cuando hay imágenes que muestran inundación, el modelo la había pronosticado). Google reporta un método donde con Sentinel-1 y clasificación GMM determinan si hubo inundación en una fecha, y verifican si su modelo hidrológico mostró evento extremo simultáneo (Google Research & Cohen, 2024). Nosotros aplicaremos una versión local: por ejemplo, tomar imágenes SAR de la baja cuenca que muestren inundación (píxeles “agua”) y confirmar que en esas fechas el LSTM + modelo inundación habrían generado alerta para esa zona. Con un registro suficiente de casos, esto permitirá “marcar” puntos de

pronóstico (gauges virtuales) como validados si pasan esta prueba al menos una vez (Google Research & Cohen, 2024).

Pruebas fuera de muestra (Pilotaje): Tras completar el desarrollo y calibración con datos históricos, se llevará a cabo un **ensayo general en tiempo real**, utilizando datos recientes nunca vistos por el sistema. Por ejemplo, se podría ejecutar el sistema usando los pronósticos meteorológicos del último año (2025) para generar pronósticos y compararlos con lo ocurrido realmente ese año. Esto emula la operación en vivo sin intervenir, y sirve para afinar detalles operativos. Adicionalmente, durante el piloto se planificará responder preguntas como: ¿con cuánta anticipación está dando alertas el modelo vs lo deseado? ¿Hubo falsos positivos significativos que deban ajustar umbrales? ¿El tiempo de cómputo diario es el esperado? Estas pruebas permiten **hacer ajustes finales** antes de la puesta en producción continua. Es importante involucrar a los usuarios finales (equipos de CEL operativos, protección civil) en esta etapa, para incorporar su retroalimentación sobre la utilidad de las alertas generadas y la claridad de la visualización.

En cuanto a los **criterios de éxito**, se espera lograr al menos un NSE medianamente alto (por ejemplo >0.8) en la predicción de caudales a 3 días y >0.7 a 7 días, lo cual equivaldría a cumplir la meta de $>80\%$ de precisión establecida en la propuesta. Para inundaciones, el objetivo es detectar todos los eventos de inundación mayor (POD $\sim 100\%$) con un falso alarmismo mínimo aceptable (ideal FAR $< 20\%$). Estas metas cuantitativas se refinarán conforme a los resultados de la validación. Todos los hallazgos de la evaluación se documentarán en un informe técnico, identificando las fortalezas del sistema y las limitaciones a mejorar en futuras iteraciones.

6. Infraestructura técnica y uso de recursos (GPU, entorno web y servicios externos)

El despliegue de este sistema se fundamenta en una **infraestructura tecnológica dedicada y comisionada específicamente para este proyecto**, garantizando así el rendimiento, la seguridad y la soberanía de los datos. Este enfoque de "silo de IA" reemplaza la idea inicial de utilizar hardware existente para asegurar que los recursos computacionales estén optimizados para las cargas de trabajo de IA sin competir con otros sistemas productivos.

La arquitectura de infraestructura propuesta está diseñada para ser un entorno on-premise de alto rendimiento, basado en el **Escenario 2 (Balanceado económico, revisado)**, el cual fue validado como la opción más equilibrada en costo y capacidad.

Arquitectura de Hardware Recomendada

Nodo	CPU	GPU	RAM	Almacenamiento	Redes	Rol operativo
------	-----	-----	-----	----------------	-------	---------------

ML Compute	/	Xeon Silver 4314 (16c)	RTX 4090 24 GB	128 GB ECC	2x 2 TB NVMe (RAID-1)	2x 10 GbE	Entrena modelos en <12h; Inferencia <30s. IPMI & PSU redundante.
Datos & ETL		Xeon E-2356 G (6c)	-	64 GB ECC	4x 4 TB SSD (RAID-10)	10 GbE	Aloja Mage, PostgreSQL/PostGIS, MongoDB y herramientas de monitoreo.
Backup NAS		Atom C3758 (8c)	-	16 GB ECC	8 TB RAID-6	2x 1 GbE	Snapshots nocturnos automatizados; soporte ZFS.

Todos los equipos se montarán en rack, serán alimentados por un UPS online de 3 kVA y se conectarán a través de un switch de 10 GbE.

Dimensionamiento de Cómputo y Almacenamiento

- **Cómputo (GPU):** La **NVIDIA RTX 4090 con 24 GB de VRAM** será la pieza central para las tareas intensivas de cómputo. Fue seleccionada para cumplir con el requisito de memoria del modelo LSTM y para garantizar que los ciclos de re-entrenamiento se completen en menos de 12 horas, permitiendo una iteración ágil. Con más de 16k núcleos CUDA, permite un procesamiento paralelo masivo, crucial para las operaciones tensoriales del deep learning.
- **Almacenamiento:** El almacenamiento se ha dimensionado con una holgura significativa. El nodo de datos cuenta con **8 TB útiles en un arreglo RAID-10 de alta velocidad** para manejar el working set del proyecto (estimado en ~0.5 TB/año), mientras que el **NAS de 8 TB en RAID-6** asegura la integridad de las copias de seguridad y el archivado a largo plazo. Se estiman entre 50-100 GB de datos históricos, pero se ha provisionado con un margen superior a 15x para dar cabida a nuevos modelos y fuentes de datos futuras.
- **Memoria (RAM):** Los **128 GB de RAM ECC** en el nodo de cómputo son cruciales para manejar grandes volúmenes de datos en memoria durante el preprocesamiento sin degradar el rendimiento, mientras los **64 GB de RAM ECC** en el nodo de datos garantizan la operación fluida de las bases de datos y la herramienta de orquestación.

Entorno de desarrollo y lenguajes

La implementación del modelo LSTM y de inundación se realizará en **Python**, aprovechando bibliotecas científicas (NumPy, Pandas, GeoPandas) y de deep learning (PyTorch, NeuralHydrology). El entorno **Node.js/React** existente en CEL será utilizado para desarrollar la interfaz de usuario (dashboard web), que se conectará a las nuevas bases de datos a través de APIs seguras. La orquestación y automatización de todo el flujo de trabajo se gestionará con **Mage** y se versionará utilizando un repositorio **Git** (ej. GitLab).

Bases de datos y almacenamiento

Como se explicó en la sección de ETL, se utilizarán las bases de datos **MongoDB** y **PostgreSQL/PostGIS**, pero estas residirán en el nuevo "Nodo de Datos & ETL" dedicado. Esta configuración asegura que las operaciones intensivas de lectura/escritura del proyecto de IA no afecten el rendimiento de las bases de datos productivas existentes de CEL. El esquema de respaldo se gestionará a través del nodo NAS dedicado.

Integración con servicios externos

Aunque la infraestructura principal es interna, el sistema seguirá dependiendo de servicios externos para tareas específicas, con costos marginales o nulos:

- **Obtención de datos meteorológicos (Externo, APIs abiertas):** Se consumirán servicios gratuitos de Copernicus/ECMWF y NASA POWER/IMERG. Se requiere una conexión a internet estable y se deben considerar mecanismos de redundancia y reintentos en los scripts de ingesta.
- **Servicios de mapas base (Externo):** Para la visualización en el dashboard, se podrán utilizar APIs de mapas como Mapbox o una solución de código abierto como OpenStreetMap para eliminar costos recurrentes. La decisión se tomará en conjunto con CEL según los requerimientos visuales y políticas de TI.
- **Notificaciones SMS/Email (Externo para SMS):** El envío de correos se realizará a través del servidor SMTP de CEL. Para las alertas críticas por SMS, se utilizará un gateway como Twilio, cuyo costo es insignificante dado el bajo volumen de alertas esperado.
- **Servicios de procesamiento satelital (Opcional, Externo):** Se podrá emplear Google Earth Engine (GEE) únicamente como herramienta de apoyo durante la fase de desarrollo para acelerar análisis geoespaciales, sin integrarlo en el flujo de producción para mantener la independencia de la nube.
- **Seguridad y disponibilidad:** La aplicación web y las bases de datos residirán en los servidores del silo de IA, protegidos por los firewalls de CEL. La redundancia se logrará a nivel de componentes de hardware (PSU, RAID) y con una robusta política de respaldos en el nodo NAS. No se contempla una replicación en la nube para el piloto.

En conclusión, esta arquitectura de infraestructura dedicada y on-premise cumple con las políticas de seguridad y soberanía de datos de CEL, a la vez que proporciona un entorno potente, escalable y optimizado para las necesidades específicas de este proyecto de

inteligencia artificial. Se maximiza la inversión en capacidad interna y se minimizan las dependencias y costos recurrentes de servicios externos.

7. Automatización y operación diaria del sistema

Para que el sistema funcione de manera fiable en el día a día, se implementará un flujo de automatización donde las distintas tareas (ingesta de datos, ejecución de modelos, generación de productos y difusión de alertas) se realicen de forma programada y con mínima intervención manual. A continuación, se describe cómo operará diariamente el sistema:

Programación de Ejecuciones

Se establecerán horarios fijos diarios para correr el pronóstico. Dado que los pronósticos meteorológicos globales suelen actualizarse hacia las 00:00 y 12:00 UTC, se programarán dos ciclos de ejecución al día: uno temprano en la mañana (e.g., 6:00 a.m. hora local) utilizando la salida del modelo de las 00 UTC, y otro en la tarde (e.g., 6:00 p.m.) con la actualización de las 12 UTC. En épocas de eventos críticos (tormentas intensas), la frecuencia podría aumentarse si la situación lo amerita.

La orquestación de estos cronogramas se realizará mediante **Mage**, que permite definir "pipelines" con dependencias complejas entre tareas (DAGs - Directed Acyclic Graphs) y programar su ejecución de forma precisa y fiable, superando las capacidades de un simple **cron**.

Flujo Diario de Ingesta y Pronóstico

Cada ciclo de ejecución seguirá una secuencia automatizada de pasos, donde cada tarea se dispara tras la finalización exitosa de la anterior:

1. **Descarga de Pronósticos Meteorológicos:** El pipeline de Mage iniciará la ejecución de un script Python para conectarse a las fuentes de datos (ej. API de ECMWF) y obtener el pronóstico de lluvia/temperatura para los próximos 7 días, así como los datos de lluvia observada de las últimas 24 horas (ej. satélite GPM).
2. **Preprocesamiento ETL:** A continuación, otro script dentro del mismo pipeline ejecutará las transformaciones necesarias: cálculo de la precipitación media en la cuenca, agregación de datos y estructuración del input para el modelo LSTM. Este paso incluye la normalización de variables según los mismos parámetros usados en el entrenamiento.
3. **Ejecución del Modelo LSTM:** Una vez preparados los datos de entrada, el pipeline de Mage activará el script de predicción. Este cargará los pesos del modelo entrenado en la GPU y computará los caudales pronosticados. Este proceso, acelerado por la GPU, es extremadamente rápido (del orden de segundos o minutos). Los resultados se pasarán a la siguiente etapa.
4. **Cálculo de Inundación y Alertas:** Con el pronóstico de caudales disponible, se alimenta al modelo de inundación. Este script compara los valores pronosticados con los

umbrales críticos predefinidos y, si se supera alguno, genera las alertas estructuradas y determina la capa geográfica de inundación correspondiente.

5. **Actualización de Bases de Datos:** Los pronósticos y las alertas generadas se almacenan de forma estructurada en las bases de datos dedicadas (MongoDB para datos en tiempo real y PostgreSQL para el histórico), asegurando la trazabilidad y disponibilidad para el dashboard y análisis futuros.
6. **Notificación y Visualización:** Finalmente, el sistema ejecuta las acciones de salida. Si se generaron alertas de nivel amarillo o rojo, se disparan automáticamente las notificaciones por correo electrónico y SMS a las listas de distribución predefinidas. Simultáneamente, el dashboard web se actualiza para reflejar los nuevos pronósticos y mapas de inundación.

Monitoreo y Gestión de Errores

La nueva arquitectura ofrece un manejo de excepciones superior. **Mage proporciona una interfaz de monitoreo visual** donde se puede rastrear el estado de cada ejecución en tiempo real. La gestión de errores se define como código dentro de los pipelines, permitiendo configurar políticas de reintento (**retries**), timeouts y lógica de contingencia. En caso de un fallo irrecuperable (ej. una API externa no responde), el sistema notificará automáticamente a los administradores (vía email o Slack) y registrará el evento detalladamente para su posterior análisis, garantizando una alta disponibilidad y una rápida capacidad de respuesta ante incidentes.

Operación Continua y Ajustes

Una vez en marcha, el sistema operará de forma autónoma. Sin embargo, durante los primeros meses se mantendrá en modo **semi-supervisado**, donde el equipo técnico de CEL revisará diariamente los resultados para detectar posibles sesgos y validar el rendimiento del modelo en condiciones reales.

Se definirá una **política de actualización del modelo**: podría ser trimestral o semestral, donde se re-entrenará el LSTM incluyendo los datos más recientes para que aprenda de nuevos eventos hidrológicos. Este proceso de re-entrenamiento, gestionado también a través de Mage y versionado en Git, asegurará que el modelo evolucione y mantenga su precisión en el tiempo. Cada nueva versión del modelo será validada para confirmar que su rendimiento es igual o superior al anterior antes de pasar a producción.

En suma, la operación diaria estará altamente automatizada mediante pipelines de datos definidos como código, requiriendo mínima intervención manual. Esto liberará a los especialistas de CEL de las tareas repetitivas de recolección y procesamiento, permitiéndoles enfocarse en la interpretación de resultados y la toma de decisiones estratégicas. Esta integración fluida de automatización robusta y supervisión humana es fundamental para la sostenibilidad y el éxito a largo plazo del sistema.

8. Visualización de resultados y sistema de alerta

La interfaz de usuario y los mecanismos de alerta son la cara visible del sistema, fundamentales para que la información generada apoye efectivamente la toma de decisiones. En este apartado se describe cómo se materializará la inteligencia generada en un **dashboard interactivo que servirá como única fuente de verdad (single source of truth)** para todos los stakeholders, y cómo un sistema de alertas proactivo asegurará que la información crítica llegue a los usuarios clave de forma oportuna.

Dashboard Web Interactivo (Node/React)

Se desarrollará un tablero de control web integrado al portal interno de CEL (posiblemente en la misma aplicación React existente para la Gerencia Comercial u otro módulo, para mantener consistencia de UX). Este dashboard estará diseñado para una audiencia mixta técnica-operativa, con enfoque en claridad y síntesis de la información. Sus características principales incluyen:

- **Mapa de la Cuenca con Capas Dinámicas:** Al centro habrá un mapa interactivo (utilizando librerías como Leaflet o Mapbox GL JS en React). Sobre este mapa se dibujará la cuenca del Río Lempa y se destacarán elementos relevantes: el trazo del río principal, la ubicación de embalses y estaciones de monitoreo, y las zonas vulnerables (p.ej., planicie del Bajo Lempa). Cuando el sistema genere un pronóstico de inundación, se superpondrá una capa semitransparente coloreada indicando el área inundable prevista. Al interactuar con esta capa, se podrán mostrar detalles como el área estimada inundada y la profundidad máxima.
- **Gráficos de Series Temporales:** En un panel lateral o inferior, se mostrarán hidrogramas pronosticados comparados con históricos. Para cada punto de interés, un gráfico de línea mostrará la evolución del caudal o nivel para los próximos 7 días, contrastado con los valores observados recientes y los umbrales de alerta. Si se dispone de pronósticos probabilísticos (p. ej., percentiles 25-75), se sombreadá el rango de incertidumbre para comunicar la confianza del modelo. Los gráficos serán interactivos, permitiendo al usuario alternar entre puntos de pronóstico y ver la información correspondiente reflejada en el mapa.
- **Tablas Resumidas y Cifras Clave:** Para usuarios operativos, se presentará un resumen tipo semáforo en una tabla de "Estado de Alertas", listando cada sitio con su nivel de riesgo actual (ej: "Bajo Lempa – Alerta Roja en 3 días"). Estas tablas se actualizarán en tiempo real y mostrarán contadores clave como "Días para posible desborde: 3" para enfatizar la anticipación.
- **Funcionalidades Interactivas Adicionales:** El dashboard incluirá opciones para que el usuario pueda seleccionar diferentes escenarios meteorológicos, consultar el historial de pronósticos y superponer capas de vulnerabilidad (poblaciones, infraestructura) sobre el mapa de inundación.

Distribución de Alertas (Email/SMS)

Aunque el dashboard es la herramienta principal, las alertas proactivas vía correo electrónico y SMS asegurarán que la información crítica llegue de inmediato. El sistema de alertas se configurará de la siguiente manera:

- **Definición de Umbrales y Destinatarios:** En coordinación con los equipos internos de CEL, se definirán umbrales cuantitativos para distintos niveles de alerta (ej. Alerta Amarilla para periodo de retorno de 5 años). Estos umbrales serán fácilmente ajustables. A cada nivel de alerta se asociará una lista de destinatarios específica dentro de la organización.
- **Contenido de las Notificaciones:** Los correos y SMS serán claros, concisos y estrictamente descriptivos. El objetivo es notificar sobre una condición pronosticada y dirigir al usuario al dashboard para su análisis. Por ejemplo:
 - **Email:** "Asunto: Alerta Roja de Inundación – Bajo Lempa. Cuerpo: Según el sistema de pronóstico IA de CEL, se anticipa que el río Lempa alcance un caudal de ~3000 m³/s el próximo miércoles a las 03:00, superando el umbral de alerta roja. Se insta a revisar el dashboard para un análisis detallado de la situación."
 - **SMS:** "ALERTA ROJA: Pronóstico de caudal >3000 m³/s en Bajo Lempa en 3 días. Revise el dashboard para más detalles. Info: [enlace_corto]".
- **Envío Automático y Lógica Anti-Spam:** La lógica del sistema detectará cuando un pronóstico cruza un umbral y enviará la notificación. Para evitar fatiga de alertas, no se reenviará el mismo aviso repetidamente; en su lugar, se enviarán actualizaciones solo si el nivel de riesgo cambia significativamente.
- **Confirmaciones y Escalamiento:** Como potencial mejora futura, se podría implementar un sistema de confirmación de recibido (ACK). Inicialmente, se llevará un registro detallado de todas las alertas enviadas para fines de auditoría.

Integración y Adopción del Sistema

- **Integración con Protocolos Existentes:** Es fundamental alinear este sistema con los protocolos de emergencia vigentes de CEL. Se coordinará con la Gerencia de Operaciones para que las alertas generadas se integren en la cadena de comunicación oficial. Una alerta roja del sistema IA, por ejemplo, podría actuar como el disparador formal para que CEL convoque su comité de emergencia hídrica y active los procedimientos internos correspondientes.
- **Ejercicios y Capacitación de Usuarios:** La adopción exitosa de la herramienta se asegurará mediante un proceso de diseño centrado en el usuario (UCD). Se realizarán sesiones de validación de prototipos en etapas tempranas y talleres de capacitación antes del despliegue final para enseñar a los usuarios a interpretar la información (p. ej., entender que una zona coloreada en el mapa es un área de riesgo potencial, no una certeza absoluta).

En resumen, el dashboard React proveerá una ventana intuitiva al estado actual y futuro del río, mientras que el subsistema de alertas garantizará que ninguna predicción crítica pase

inadvertida. Juntos, conforman la interfaz humana del sistema de IA, traduciendo datos complejos en información accionable para la toma de decisiones, la gestión oportuna de crecidas e influjos, respuesta anticipada ante eventos hidrológicos extremos y por consecuencia la optimización de la operación hidrológica.

9. Consideraciones operativas específicas del Río Lempa

La implementación para la cuenca del Río Lempa conlleva retos y particularidades que deben ser considerados para garantizar la efectividad del sistema en contexto real. A continuación se abordan las principales consideraciones operativas, derivadas de la naturaleza trinacional de la cuenca, sus zonas críticas de inundación y la presencia de infraestructura hidráulica:

Coordinación trinacional y datos transfronterizos: El Río Lempa atraviesa Guatemala, Honduras y El Salvador, con una cuenca de ~18,200 km² compartida entre los tres países. Esto implica que eventos hidrológicos en la parte alta (Guatemala/Honduras) repercuten aguas abajo en El Salvador. Un desafío es la disponibilidad de datos en las secciones transfronterizas. Idealmente, se establecerá intercambio de datos en tiempo real con las entidades homólogas (p. ej., INSIVUMEH en Guatemala, SMN en Honduras) sobre lluvias y caudales en la cuenca alta. En la práctica, tal coordinación puede requerir convenios o acuerdos diplomáticos. Mientras eso se consolida, el sistema está diseñado para suplir la falta de datos mediante fuentes globales: las precipitaciones satelitales (GPM/CHIRPS) cubren toda la cuenca independientemente de fronteras, y los pronósticos globales (ECMWF) igualmente abarcan Guatemala y Honduras. Así, **aunque no lleguen datos locales de esos países, el modelo podrá estimar caudales entrantes**. No obstante, se recomienda en paralelo avanzar en acuerdos para obtener lecturas de caudal de ríos tributarios que ingresan a El Salvador, lo que permitiría afinar el modelo con datos directos. Otro punto es el idioma y la comunicación: las alertas probablemente deban compartirse con contrapartes en los países vecinos en caso de eventos que los afecten (por ejemplo, una crecida que inunde parte de Ocotepeque, Honduras). Se prevé generar reportes bilingües (o en español estándar comprensible regionalmente) para facilitar este intercambio. Además, el sistema podría ampliarse a futuro para dar **pronósticos en puntos dentro de Guatemala u Honduras**, si hay interés y colaboración, haciendo del Lempa un piloto de alerta temprana regional.

Zonas críticas de inundación – enfoque en el Bajo Lempa: La zona del **Bajo Lempa** en El Salvador (parte baja de la cuenca, departamentos de San Vicente y Usulután) es reconocida por su alta vulnerabilidad a inundaciones. Terrenos planos, comunidades agrícolas densamente asentadas y antecedentes de eventos severos (ej. Huracán Mitch 1998, Tormenta Ida 2009, etc.) la convierten en prioridad. El sistema se calibrará cuidadosamente para esta zona: el modelo de inundación incluirá las llanuras aluviales del Bajo Lempa con el mayor detalle disponible (DEM refinado, inclusión de diques y bordos de contención en los datos geoespaciales). Es crucial incorporar la existencia de infraestructura de protección: en Bajo Lempa existen **bordos/levées** construidos para contener inundaciones hasta cierto nivel. Estos bordos serán mapeados y sus cotas añadidas al DEM para que el modelo de inundación no

“inunde” detrás de ellos hasta que el nivel supere su altura. También se identificarán puntos de quiebre: lugares donde históricamente se rompen los diques cuando hay crecidas extraordinarias. Toda esta información local se integrará en los escenarios de inundación. Además, se consultará a expertos locales de SNET y Protección Civil sobre **umbrales empíricos** (por ej: “con 1500 m³/s ya se sale el río en sector X”), para validar los umbrales teóricos calculados. Operativamente, en temporada de lluvias intensas se podría activar un monitoreo reforzado en Bajo Lempa: por ejemplo, aumentando la frecuencia de pronóstico a 6 horas si un huracán está impactando, y asegurando que la comunicación con líderes comunales esté lista vía las alertas. Como la zona es agrícola, se valorará también la posibilidad de que el dashboard muestre **parcelas o caseríos en riesgo** para facilitar la respuesta (posible con capas GIS adicionales).

Influencia de embalses y regulación hidráulica (La “Garganta de Cuscatlán”): En la cuenca media del Lempa se encuentran varios embalses hidroeléctricos administrados por CEL (como 5 de Noviembre, Cerrón Grande, 15 de Septiembre). En particular, el embalse **Cerrón Grande** – a veces referido por su estrecho de salida como la “Garganta de Cuscatlán” – juega un papel doble: por un lado, amortigua crecidas al retener parte del flujo, pero por otro, requiere descargas controladas que si no se gestionan proactivamente pueden agravar una inundación aguas abajo. El sistema de pronóstico se implementará de la mano con el centro de control de embalses para aprovecharlo en la **optimización de la operación de represas**. Esto significa que, con varios días de anticipación de una crecida, CEL podría decidir aumentar generación o abrir compuertas moderadamente para bajar el nivel del embalse y **ganar capacidad de almacenamiento** antes de la llegada del pico (esto ya se menciona como beneficio esperado en la propuesta). Nuestro modelo LSTM deberá, por tanto, pronosticar los **caudales afluentes a los embalses** con precisión, y con eso, podremos simular escenarios de operación. Aunque el modelo en sí no optimiza la presa, los operadores, al ver el pronóstico, podrán determinar un plan óptimo (posiblemente asistidos por alguna regla sugerida, e.g., “liberar X m³/s por Y horas”). La integración consiste en que el dashboard resaltará el **nivel previsto del embalse** si se aproxima al máximo operativo, para que se tomen acciones.

En cuanto a la modelación, las presas introducen discontinuidades: por ejemplo, si el embalse está muy bajo, puede absorber toda una avenida sin soltar nada hasta cierto punto, pero si está lleno, cualquier excedente se va a vertir aguas abajo. Estas condiciones se pueden codificar en el modelo. Una forma es segmentar el río en tramos: caudal afluente (pronosticado por LSTM) -> modelo simple de embalse (balance volumen con nivel, usando curvas de capacidad) -> caudal efluente. Podríamos implementar un sub-módulo que dado un pronóstico de afluencia, calcule la respuesta del embalse según su nivel actual y política de operación (por ejemplo: turbinar máximo hasta que suba a nivel X, luego abrir compuertas). Si CEL provee sus **curvas de operación** y datos nivel-volumen, esto se puede incorporar. Durante el piloto, se podrá hacer pruebas con y sin esa lógica para ver diferencias. En cualquier caso, **la Garganta de Cuscatlán** se convierte en un punto de control clave: allí mediremos qué tanto lograremos reducir el pico con acciones, comparando escenarios. Esta funcionalidad tiene un gran **valor estratégico** para

CEL, pues no solo es alerta temprana sino también **optimización hidroeléctrica** – evitar vertidos de emergencia y aprovechar el agua para generación .

Comunicación interinstitucional: Operativamente, el éxito depende de la comunicación entre áreas de CEL (operadores de centrales, unidad de gestión de riesgo) y externamente con Protección Civil y gobiernos locales. Se propondrá la creación de un **procedimiento operativo estándar (SOP)** que indique qué hacer cuando el sistema emite una alerta. Por ejemplo: “Si alerta roja pronosticada a 3 días, convocar comité de emergencia hídrica de CEL en 12 horas; informar a Protección Civil para posible alerta pública 48 horas antes; preparar cierre preventivo de compuertas de riego en Bajo Lempa”, etc. Este SOP se puede anexar al plan de emergencia de CEL y será afinado con los involucrados. En pruebas piloto, se simularán escenarios (ej. un taller de simulación de inundación) para practicar esta coordinación.

Factores externos locales: Hay particularidades como la acumulación de sedimentos en cauce bajo, deforestación en cuenca alta, mareas altas coincidentes en la desembocadura, etc., que pueden influir en inundaciones. Estos factores son difíciles de incluir explícitamente en el modelo de IA pero deben tenerse en cuenta en la interpretación. Por ejemplo, si se sabe que justo cuando hay marea alta el Lempa desagua más lento, un operador experto puede añadir ese juicio ante un pronóstico. Se buscará recopilar este conocimiento empírico local para documentarlo en manuales de uso del sistema. También, tras eventos, se hará *post-mortem*: ¿el modelo falló por algo no considerado, como un dique roto o un deslizamiento bloqueando el cauce? Esos aprendizajes se incorporarán, tal vez ajustando modelos (ej.: si se identifica que con suelos saturados de 15 días el comportamiento cambia, se podría añadir esa variable).

En suma, la aplicación en el Río Lempa requiere un enfoque integral: **regional (3 países), local (Bajo Lempa) y operativo (presas)**. Las configuraciones del sistema se personalizarán para reflejar esa realidad: pronósticos probables en secciones transfronterizas, mapas detallados en zonas críticas, integración con manejo de embalses en Garganta de Cuscatlán. Este pilotaje servirá para mostrar cómo un modelo global de IA se adapta a las condiciones concretas de una cuenca, potenciando la resiliencia hídrica con conocimiento tanto tecnológico como tradicional local.

10. Recursos humanos y perfiles técnicos necesarios

La implementación y operación exitosa de este sistema de pronóstico hidrológico con inteligencia artificial requerirá un equipo multidisciplinario que combine el liderazgo estratégico de una consultora externa con el talento técnico y el conocimiento local del personal de CEL. La naturaleza de este proyecto será fundamentalmente colaborativa, donde la consultora, operando de forma remota, proveerá el diseño, la arquitectura y la guía experta, mientras que el equipo de CEL será responsable de la ejecución, implementación y validación en el entorno local.

A continuación, se detallan con profundidad los perfiles clave y la naturaleza de su involucramiento:

- **Consultora Líder en IA e Ingeniería de Datos (externo):** Este rol será desempeñado por la consultora externa. Será responsable directa del **diseño, desarrollo e implementación del modelo** basado en redes neuronales LSTM, la **estrategia de ingeniería de datos utilizando Mage**, y el **diseño del dashboard web**. A lo largo de todas las fases, guiará remotamente al equipo de CEL, proporcionando especificaciones técnicas, liderando sesiones de co-desarrollo de código y supervisando la correcta implementación de la arquitectura. Finalmente, liderará la documentación técnica exhaustiva del proyecto.
- **Líder Técnico en Hidrología y Gerente de Proyecto (interno CEL):** Como **Gerente de Proyecto**, supervisará integralmente su ejecución, manejando cronogramas, comunicación interinstitucional y asignación de recursos. Como **Líder Técnico en Hidrología**, proporcionará la orientación experta y el conocimiento empírico del río Lempa, siendo fundamental para interpretar la dinámica hidrológica, validar los resultados del modelo y asegurar que las predicciones sean coherentes y operativamente útiles.
- **Administrador de Sistemas / Ingeniero DevOps (interno CEL):** Su rol será protagónico durante la **Fase 0**. Liderará la **implementación física y configuración** de la nueva infraestructura de servidores ("AI Silo"), incluyendo el 'racking', la conexión de red y la instalación inicial, siguiendo las especificaciones y la guía remota de la consultora. Dada su extensa experiencia en DevOps, será responsable de establecer el entorno para la nueva herramienta de orquestación (Mage) y de configurar el repositorio **Git/GitLab** para el control de versiones del código, sentando las bases para la automatización (CI/CD) y la mantenibilidad del sistema.
- **Ingenieros de Datos y Backend (interno CEL):** Como expertos en el stack de datos de CEL, su rol será crucial en la migración de la lógica de negocio a los nuevos pipelines de Python en Mage. Trabajarán en sesiones de **desarrollo colaborativo (pair programming)** con la consultora para **desarrollar, probar y desplegar los flujos de ETL como código**, aprovechando su experiencia en Python, SQL y bases de datos. Serán los responsables de ejecutar las pruebas de validación para asegurar que los nuevos pipelines se integren correctamente con las fuentes de datos existentes.
- **Especialista SIG/Teledetección (interno CEL):** Trabajará en estrecha colaboración con la consultora para manejar los aspectos geospaciales del proyecto. Será responsable de la **ejecución local del procesamiento** de imágenes satelitales (Sentinel-1) y la preparación del Modelo Digital de Elevación (DEM), siguiendo las metodologías y scripts proporcionados.
- **Hidrólogo Operativo (interno CEL):** Este profesional operativo aportará conocimiento empírico crucial durante todo el proyecto. Será el usuario principal del sistema, encargado de monitorear diariamente su desempeño, interpretar las alertas y servir como **validador final** de que los resultados del modelo son coherentes y útiles para la operación diaria.

Este esquema de equipo no solo asegura una ejecución técnica robusta, sino que está diseñado para una transferencia de conocimiento efectiva, posicionando a CEL con capacidades internas sólidas para operar, mantener y evolucionar esta solución de inteligencia

artificial, fortaleciendo significativamente la gestión oportuna de crecidas e influjos, respuesta anticipada ante eventos hidrológicos extremos y por consecuencia la optimización de la operación hidrológica en la cuenca del río Lempa.

Detalle de Tareas y Matriz de Roles (RACI)

Con el objetivo de asegurar una implementación técnica robusta y una transferencia de conocimiento efectiva, se estructura a continuación el desglose detallado de tareas por fase, así como la matriz de roles y responsabilidades asociadas al equipo multidisciplinario involucrado en el proyecto de pronóstico hidrológico con inteligencia artificial.

Tabla de tareas por fase del proyecto

Fase	Tarea Principal	Responsable	Apoyo / Observaciones
Fase 0: Infraestructura	Diseño del entorno técnico y arquitectura general	Consultora IA	Define especificaciones para AI Silo, Git, Mage
	Montaje físico de servidores e infraestructura (AI Silo)	Administrador de Sistemas / Ingeniero DevOps (CEL)	Siguiendo guía remota de la consultora
	Configuración de red aislada, accesos VPN, usuarios	Administrador de Sistemas / Ingeniero DevOps (CEL)	Validación remota por la consultora
	Instalación de Mage, GitLab y entorno base de orquestación	Administrador de Sistemas / Ingeniero DevOps (CEL)	Consultora provee documentación y soporte
Fase 1: Preparación de datos	Migración de lógica de negocio a nuevos pipelines	Ingenieros de Datos y Backend (CEL)	Pair programming con la consultora
	Desarrollo de flujos ETL en Python usando Mage	Consultora Líder en IA + Ingenieros de Datos (CEL)	Validación cruzada conjunta

	Pruebas de integración de pipelines con fuentes internas	Ingenieros de Datos y Backend (CEL)	Consultora supervisa
	Documentación técnica de pipelines y estructura de datos	Consultora Líder en IA	Para transferencia futura
Fase 2: Modelado IA	Desarrollo e implementación del modelo LSTM	Consultora Líder en IA	Apoyo conceptual del líder hidrológico
	Selección y justificación de variables de entrada	Consultora Líder en IA + Líder Técnico en Hidrología (CEL)	Basado en contexto del Lempa
	Entrenamiento y validación cruzada del modelo	Consultora Líder en IA	Iteración con CEL
	Documentación del modelo y resultados de validación	Consultora Líder en IA	Base para publicaciones futuras
Fase 3: Visualización y operación	Implementación del dashboard web	Consultora Líder en IA	Entorno React + GIS, seguimiento remoto
	Generación de mapas estáticos y capas cartográficas	Especialista SIG / Teledetección (CEL)	Con scripts provistos por la consultora
	Validación funcional y operativa del sistema	Hidrólogo Operativo (CEL)	Usuario principal del sistema
	Ajuste final del sistema basado en retroalimentación	Consultora Líder en IA + Equipo CEL	Mejora continua antes de cierre técnico

Matriz RACI de Roles y Responsabilidades

Actividad / Entregable	Consultora IA	Líder Técnico en Hidrología (CEL)	Administra dor de Sistemas / Ingeniero DevOps (CEL)	Ingeniero s de Datos y Backend (CEL)	Especialist a SIG / Teledetecci ón (CEL)	Hidrólogo Operativo (CEL)
Diseño arquitectura AI	R / A	C	I	C	I	I
Implementación infraestructura (Fase 0)	C	I	R / A	I	I	I
Configuración Mage + GitLab	C / A	I	R	I	I	I
Desarrollo pipelines ETL	R / C	I	I	R / A	I	I
Validación pipelines	A / R	C	I	R	I	I
Diseño y entrenamiento IA	R / A	C / I	I	C	I	C
Visualización (dashboard)	R	I	I	I	C	C
Cartografía y mapas SIG	C / A	I	I	I	R	I

Validación operacional	C	I	I	I	I	R / A
Gestión y coordinación	C	R / A	I	I	I	I

Leyenda:

- **R** = Responsable de ejecutar la tarea
- **A** = Aprobador final de la actividad
- **C** = Consultado para contribuir técnicamente o validar
- **I** = Informado del progreso y entregables clave

Este esquema permite asegurar que todas las tareas estén claramente asignadas, las responsabilidades debidamente distribuidas y que la interacción entre consultora externa y equipo CEL esté coordinada para maximizar la eficiencia y sostenibilidad del proyecto.

Citations

Google Research, & Cohen, D. (2024, November 11). An improved flood forecasting AI model, trained and evaluated globally.

<https://research.google/blog/a-flood-forecasting-ai-model-trained-and-evaluated-globally/#:~:text=Our%20prior%20ML%20hydrologic%20model,is%20built%20on%20an%20LSTM>

Nearing, G., Cohen, D., Dube, V., Gauch, M., Gilon, O., Harrigan, S., Hassidim, A., Klotz, D., Kratzert, F., Metzger, A., Nevo, S., Pappenberger, F., Prudhomme, C., Shalev, G., Shenzen, S., Tekalign, T. Y., Weitzner, D., & Matias, Y. (2024). Global prediction of extreme floods in ungauged watersheds. *Nature*, 627(8004), 559–563.

<https://doi.org/10.1038/s41586-024-07145-1>

Nevo, S., Morin, E., Rosenthal, A. G., Metzger, A., Barshai, C., Weitzner, D., Voloshin, D., Kratzert, F., Elidan, G., Dror, G., Begelman, G., Nearing, G., Shalev, G., Noga, H., Shavitt, I., Yuklea, L., Royz, M., Giladi, N., Levi, N. P., . . . Matias, Y. (2022). Flood forecasting with machine learning models in an operational framework. *Hydrology and Earth System Sciences*, 26(15), 4013–4032. <https://doi.org/10.5194/hess-26-4013-2022>

Anexo Técnico B: Propuesta de Infraestructura Local para el Silo de IA de CEL

Documento dirigido al Comité Técnico y al Área de Informática de CEL

Objetivo: validar y formalizar una infraestructura y arquitectura local que cumpla el piloto de Pronóstico Hidrológico, reduzca riesgos operativos y sienta la base para futuras iniciativas de IA dentro de CEL.

1. Contexto y Principios

Durante la última ronda técnica se revisaron tres escenarios de infraestructura. Tras contrastarlos con los requisitos del piloto, las políticas de datos sensibles de CEL y las buenas prácticas de MLOps, se propone el **Escenario 2 (Balanceado económico, revisado)** con los principios:

1. **Soberanía y seguridad de datos:** cómputo on-prem en red aislada, con accesos de salida controlados.
2. **Fiabilidad industrial:** componentes ECC, IPMI/BMC y PSU redundantes para minimizar MTTR.
3. **Escalabilidad modular:** dominios lógicos independientes (ML, Datos & ETL, Backup) que crecen añadiendo nodos idénticos.

2. Resumen de la Arquitectura Recomendada (Escenario 2, Revisado)

Nodo	CPU	GPU	RAM	Almacenamiento	Redes	Rol operativo
ML / Compute	Xeon Silver 4314 (16 c)	RTX 4090 24 GB	128 GB ECC	2× 2 TB NVMe (RAID-1)	2× 10 GbE	Entrena en ~10 h; infiere en <30 s. IPMI & PSU redundante.
Datos & ETL	Xeon E-2356G (6 c)	—	64 GB ECC	4× 4 TB SSD RAID-10 + 1 TB NVMe OS	10 GbE	Aloja Pentaho, Postgres/PostGIS, MongoDB, Grafana.
Backup NAS	Atom C3758 (8 c)	—	16 GB ECC	8 TB RAID-6	2× 1 GbE	Snapshots nocturnos; soporte ZFS scrub.

Todos los equipos se montan en **rack 2U**, alimentados por un **UPS online 3 kVA** (30 min autonomía) y conectados a un switch 10 GbE.

3. ¿Cuántos datos moveremos realmente?

Conjunto de datos	Cálculo de volumen	Implicación
-------------------	--------------------	-------------

Series hidrometeo históricas	46 años × 365 d ≈ 16 800 registros × 20 campos ≈ 3 MB	Caben completos en memoria; recarga instantánea.
Precipitación & temperatura (ERA5, GPM)	Cobertura 30 000 km ² (≈ 1 200 celdas/día). 46 años ⇒ ≈ 10 GB	Se almacena una sola vez; se resume al ingresar.
Imágenes Sentinel-1 de inundación	20 eventos/año × 20 MB × 10 años ⇒ ≈ 4 GB	Solo para ajustar el modelo de extensión de inundación.
Total piloto	≈ 15–25 GB ; se redondea a 50–100 GB para 3-5× holgura	Justifica 8 TB de SSD RAID-10 + 8 TB NAS para crecimiento > 5 años.

Conclusión: los volúmenes son modestos; el almacenamiento propuesto ofrece un margen > 30× respecto al piloto.

4. Dimensionamiento de Cómputo (GPU + RAM)

Parámetro clave	Derivación	Valor
Longitud de secuencia	1 año de historial → 365 pasos	365
Tamaño de lote (training)	32 secuencias	32
Memoria de activación	365 × 32 × 256 unidades × 4 bytes ≈ 12 MB	< 24 GB VRAM
Cálculo por época	~2 GFLOP/seq → 23 TFLOP por época	
RTX 4080	82 TFLOP FP32 → 23 TF / 82 TF/s ≈ 17 min/época	30 épocas ≈ 9 h

Por qué importa: entrenar en < 12 h permite iterar cada noche y validar resultados cada mañana. La RAM ECC de 128 GB evita swapping cuando ETL y rasterización comparten el nodo.

5. Dimensionamiento de Almacenamiento

Working set estimado = 100 GB (ver § 3) + artefactos intermedios (200 GB) + checkpoints trimestrales (8 × 25 GB) ≈ **0,5 TB/año**.

4 × 4 TB SSD RAID-10 ⇒ 8 TB útiles, 16× margen a 5 años, duplicación de lectura y tolerancia a 2 fallos de disco.

6. Consumo Energético y OPEX

Componente	Potencia media*	kWh/año	Coste estimado
Nodo GPU	0,79 kW	6 900	—
Datos & ETL	0,25 kW	2 190	—
NAS + Red	0,08 kW	700	—
Total	≈ 1 kW	≈ 9 800 kWh	? \$/año

Potencia media = (200 W idle × 14 h + 700 W training × 10 h) / 24 h para el nodo GPU.

Nota sobre el coste energético: hemos usado un tarifario de referencia de **0,15 USD/kWh** (media industrial regional). Agradecemos a CEL confirmar su tarifa vigente para ajustar el OPEX (p.ej. 0,13 USD/kWh reduciría ~200 USD/año).

Si se mantiene 0,15 USD/kWh: 9 800 kWh × 0,15 = **1 470 USD/año** (ya reflejado en la tabla de CAPEX/OPEX).

7. Alineación Infra-Requisitos del Piloto

Requisito (Anexo Técnico)	Elemento de infraestructura que lo cubre
Entrenamiento < 12 h	RTX 4090 + NVMe RAID-1
Inferencia doble diaria < 30 s	24 GB VRAM + Xeon 4314
Retener 50–100 GB/año de datos	SSD RAID-10 8 TB
Copias nocturnas (política de respaldo)	NAS 8 TB RAID-6 + ZFS
Escalar a futuros pilotos (mantenimiento predictivo, etc.)	Añadir nodos GPU idénticos vía 10 GbE

8. Coste Total de Propiedad

Concepto	CAPEX único	OPEX anual
Hardware (3 nodos + UPS + cableado)	15 600 USD	—

Electricidad (basado en tarifa 0,15 USD/kWh)	—	1 470 USD
Repuestos preventivos (SSD/fans)	—	300 USD
Soporte Pro (opcional)	—	1 000 USD
Total OPEX	—	≈ 2 770 USD/año

El coste eléctrico variará $\pm 13\%$ por cada 0,02 USD/kWh de diferencia en la tarifa.

9. Conclusión

La solución propuesta mantiene los datos críticos dentro de CEL, reduce el CAPEX al mínimo viable y ofrece un camino de crecimiento lineal. Los cálculos de datos, cómputo y energía se fundamentan en el Anexo Técnico y garantizan que los SLAs de entrenamiento e inferencia se cumplan desde el día 1.

Anexo Técnico C: Lista de Materiales (BOM)

Cliente: Comisión Ejecutiva Hidroeléctrica del Río Lempa (CEL)

Proyecto: Plataforma de Pronóstico Hidrológico con IA

Fecha: Aug 26, 2025

Moneda: Dólares de los Estados Unidos (USD)

Entrega Estimada: ASAP (sujeto a disponibilidad de componentes y tiempos de envío internacionales, típicamente 1-3 semanas)

1. Hardware e Infraestructura Propuesta

A continuación se detalla el Bill of Materials (BoM) de hardware e infraestructura para el proyecto, con opciones de marcas/modelos recomendados, precios reales estimados en USD (compra en EE.UU. con envío a El Salvador), plazos de entrega aproximados y enlaces a proveedores. Los componentes están separados por nodo/función:

Ítem	Descripción (Marca/Modelo recomendado)	Cant.
1. Nodo de Cómputo AI	Servidor GPU 4U para IA. Incluye CPU: Intel Xeon Silver 4314, 16 núcleos/32 hilos, 2.4 GHz base (3.4 GHz turbo)[1] GPU: NVIDIA GeForce RTX 4090 24 GB GDDR6X (tarjeta GPU de alto rendimiento para IA)[2]	1

Ítem	Descripción (Marca/Modelo recomendado)	Cant.
	Placa Madre: Supermicro X12SPM-TF (LGA4189, Intel C621A, soporte Xeon 3ra Gen., doble LAN 10GbE integrado) – <i>Opción</i>: ASUS P12R-E/10G-2T (ATX, Intel C256, doble 10GBase-T)[3] RAM: 128 GB DDR4 ECC (4×32 GB RDIMM, 3200 MT/s)[4] Almacenamiento: 2× SSD NVMe M.2 de 2 TB (RAID-1 para S.O. y datos rápidos)[5] <i>(Chasis y PSU cotizados por separado)</i>	
2. Nodo de Datos	Servidor de almacenamiento/ETL 2U. Incluye: CPU: Intel Xeon E-2356G, 6 núcleos/12 hilos, 3.2 GHz (5.0 GHz turbo)[6] Placa Madre: ASUS P12R-M/10G-2T (uATX, Intel C252, doble 10GBase-T X710-AT2 integrado) – <i>Opción</i>: Supermicro X12STL-IF + tarjeta NIC 10GbE Intel X550 RAM: 64 GB DDR4 ECC (2×32 GB UDIMM, 3200 MT/s) Almacenamiento: 4× SSD 4 TB SATA (RAID-10, ~8 TB utilizable) – ej. Samsung 870 EVO 4TB[7] <i>(Chasis y PSU cotizados por separado)</i>	1
3. Nodo NAS de Respaldo	Servidor NAS 2U para backups. Incluye CPU/Placa: Supermicro A2SDi-H-TF (Mini-ITX con CPU Intel Atom C3758 8 núcleos @2.2 GHz integrada, 16 GB ECC RAM, doble 10GBase-T)[10][11] RAM adicional: +16 GB DDR4 ECC (total 32 GB) Almacenamiento: 4× HDD 4 TB NAS (RAID-6, ~8 TB netos) – ej. Western Digital Red Plus 4TB, 5400 RPM, CMR[12] <i>(Chasis y PSU cotizados por separado)</i>	1

Ítem	Descripción (Marca/Modelo recomendado)	Cant.
4. Chasis Rack 4U – Nodo de Cómputo	Gabinete rack 19" 4U profundo, compatible E-ATX (GPU larga). Ej.: In Win R400 o Rosewill RSV-L4500 (hasta 15 bahías internas). Incluye ventiladores de alto flujo frontales/traseros para enfriar la GPU. <i>Nota:</i> Sin fuente; se instala PSU ATX por separado.	1
5. Chasis Rack 2U – Nodo de Datos	Gabinete rack 19" 2U corto, micro-ATX, con mínimo 4 bahías para unidades de 3.5"/2.5". Ej.: Rosewill o iStarUSA 2U (4 bahías frontales fijas u hot-swap). Incluye ventiladores 80 mm. <i>Nota:</i> Sin fuente (PSU se cotiza aparte).	1
6. Chasis Rack 2U – Nodo NAS	Gabinete rack 19" 2U compacto para Mini-ITX. Ej.: Supermicro SC505 (4 bahías hot-swap de 3.5", backplane SATA) o Chenbro equivalente. Incluye ventiladores. <i>Nota:</i> Fuente de poder flex ATX o SFX se agrega aparte.*	1
7. Fuente Alimentación 1200 W (80+ Plat.)	Fuente de poder ATX 1200 W certificación 80 Plus Platinum, modular, para nodo de cómputo (ej. Seasonic Vertex PX-1200 ATX 3.0)[17]. Soporta pico de ~600 W del RTX 4090 + CPU.	1
8. Fuente Alimentación 600 W (80+ Gold)	Fuente ATX 600 W 80+ Gold, modular, para nodo de datos. Ej.: EVGA 600 W o Corsair RM650e. Suficiente para Xeon E + 4 SSD (consumo ~150 W máx.).	1
9. Fuente Alimentación 300 W (Flex ATX)	Fuente 300 W 80+ Bronze (perfil bajo) para nodo NAS. Ej.: SilverStone FX350-G (Flex ATX) o adaptador externo 12 V DC + módulo DC-ATX (Atom C3758 ~25 W TDP).	1
10. Sistema UPS 3 kVA (2400 W)	Sistema UPS (Fuente de Poder Ininterrumpida) en rack 2U, ~3000 VA / 2700 W, en línea interactiva/senoidal. Ej.: APC Smart-UPS 3000VA 120 V (modelo SMT3000RM2U o SRT3000) con módulos de baterías internas[19].	1

Ítem	Descripción (Marca/Modelo recomendado)	Cant.
	Autonomía aprox. 5–10 min a plena carga (extensible).	
11. Switch de Red 10 GbE	Switch Ethernet 10 Gigabit de capa 2 para interconectar los nodos a alta velocidad. Ej.: Netgear XS508M (8 puertos 1/2.5/5/10GBASE-T + 1 SFP+; no administrado)[20] – Capacidad 10 Gbps en cobre RJ45 (compatible con NICs integradas). <i>Alternativa:</i> Mikrotik CRS309 (8× SFP+ ópticos) con transceptores RJ45 10G.	1
12. Rack, Cableado y Accesorios	Cabling: Cables de red Cat6A 10 Gigabit de alta calidad para cada enlace (ej. 3× cables @2 m) y cables de energía compatibles. Accesorios: Juegos de rieles deslizantes para chasis (en caso no vengan incluidos), tornillería, bridas, bandejas organizadoras, etc.	1 lot

2. Software, Herramientas de Datos y Servicios

Se detalla el stack de software propuesto – todas las herramientas son de código abierto, sin costos de licencia. Se indica el tipo de licencia, costos estimados (si alguno), y opciones de soporte o capacitación profesional:

Software / Servicio	Descripción y Licenciamiento	Costo Licencia	Opciones de Soporte/Capacitación
Mage (Mage AI) – ETL pipelines	Plataforma de orquestación de ETL/ELT para datos. Código abierto bajo licencia Apache 2.0[21]. Entorno amigable (UI tipo notebook) para crear pipelines de ingestión, transformación y carga de datos con Python, R o SQL. Despliegue local (Docker/Pip).	\$0 (OSS)	Comunidad OSS (Slack, GitHub). <i>Mage Pro:</i> Versión empresarial opcional con orquestación avanzada y flujos asistidos por IA[22][23] – requiere suscripción (costo a cotizar con Mage.ai). Soporte profesional disponible por Mage (contrato enterprise).
PostgreSQL + PostGIS – BD geoespacial	Sistema gestor de base de datos relacional SQL (PostgreSQL) con extensión PostGIS para GIS. Licencia PostgreSQL License (libre BSD-like, aprobada OSI)[24]; PostGIS bajo GPL. Sin coste por uso, incluso comercial[24].	\$0 (OSS)	Comunidad: Documentación abundante, foros y mailing lists. Soporte pago opcional: empresas como EDB, Crunchy Data ofrecen soporte empresarial (p. ej. desde ~\$3,000 USD/año por instancias pequeñas). Capacitación formal disponible vía terceros.
MongoDB (Community) – BD NoSQL	Base de datos NoSQL orientada a documentos (JSON). Versión Community bajo licencia SSPL v1 (Server Side Public License) – código abierto “source available”; uso libre interno sin	\$0 (Community)	Comunidad: Foros oficiales, extensa documentación. Opciones Enterprise: <i>MongoDB Enterprise Advanced</i> (soporte oficial, herramientas extra) – licencia comercial anual (costo

Software / Servicio	Descripción y Licenciamiento	Costo Licencia	Opciones de Soporte/Capacitación
Grafana – Dashboard & Monitoreo	costo[25]. Ideal para almacenar datos semi-estructurados (e.g. colecciones de series temporales).		según nodos/CPU, a cotizar). <i>MongoDB Atlas (Cloud)</i> : servicio DBaaS en la nube, pago mensual según uso (p.ej. instancia M10 ~\$60/mes)[26].
	Plataforma de visualización de datos y monitorización (dashboarding). Software código abierto AGPL v3 (núcleo Grafana OSS) desde v8+[27]. Permite graficar datos de PostgreSQL, MongoDB, APIs, etc., con alertas en tiempo real.	\$0 (OSS)	Comunidad OSS: Soporte vía foros de Grafana Labs, recursos en línea. Grafana Enterprise (opcional): Binary con licencia propietaria gratuita para uso interno sin modificar código[28], desbloqueable a versión completa con plugin enterprise mediante licencia comercial. <i>Soporte Pro</i> : Grafana Labs ofrece planes Enterprise (incluye plugins avanzados, RBAC, soporte oficial). Costo ref.: ~ \$25k USD/año (mínimo) para entorno on-prem[29].
Bibliotecas Python (IA & GIS)	Conjunto de librerías de Python de código abierto para IA y geodatos, incluyendo: - PyTorch (redes neuronales deep learning, lic. BSD/MIT). - scikit-learn, pandas, NumPy (análisis de datos, lic. BSD). - GeoPandas, GDAL (GIS, licencias BSD/MIT). Estas herramientas permiten desarrollar, entrenar y ejecutar modelos de IA y procesar datos geoespaciales.	\$0 (OSS)	Comunidad de desarrolladores (StackOverflow, foros específicos de cada librería). Documentación oficial extensa y ejemplos disponibles. <i>Opcional</i> : Soporte comercial a través de terceros (p. ej. Anaconda Inc. ofrece servicios de soporte empresarial para entornos Python). Capacitación disponible mediante cursos en línea o talleres in-company.
Sistema de Backup (ZFS)	Sistema de archivos con gestión de volúmenes integrado y soporte de instantáneas (snapshots) y replicación: OpenZFS (implementación en Linux o BSD). Código abierto CDDL/MIT (sin costo). Se utilizará ZFS para el NAS de respaldo, aprovechando RAID-Z2 (equivalente RAID-6) y	\$0 (OSS)	Comunidad OpenZFS (foros, wiki). Documentación rica (ej. administradores de FreeNAS/TrueNAS). <i>Opcional</i> : TrueNAS Core (distribución NAS basada en ZFS) – gratuita; TrueNAS Enterprise con soporte oficial (requiere hardware de iXsystems). Capacitación ZFS disponible mediante consultores especializados si se requiere.

Software / Servicio	Descripción y Licenciamiento	Costo Licencia	Opciones de Soporte/Capacitación
	snapshots para puntos de recuperación.		

Anexo Técnico D: *Riesgos Menores Identificados y Planes de Mitigación*

Como parte del análisis técnico y operativo del piloto propuesto, se identifican los siguientes riesgos, incluyendo aquellos asociados a la nueva infraestructura y herramientas, junto con las estrategias propuestas para su mitigación:

Riesgo Potencial	Descripción	Relevancia para el Piloto	Plan de Mitigación
Retrasos en la Adquisición de Hardware	El comisionamiento del "AI Silo" depende de la adquisición de nuevos servidores. Pueden ocurrir retrasos por parte de los proveedores.	Medio	Iniciar el proceso de adquisición y obtener cotizaciones formales inmediatamente después de la aprobación del proyecto. Identificar proveedores alternativos.
Curva de Aprendizaje de Nuevas Herramientas (Mage)	La adopción de una nueva herramienta de orquestación (Mage) podría tener una curva de aprendizaje que impacte el cronograma de la Fase 0.	Bajo	Se proveerá capacitación dedicada. El equipo técnico de CEL posee una fuerte base en Python y DevOps, lo que mitiga significativamente este riesgo.
Complejidad en la Configuración de Acceso Remoto	El establecimiento de un acceso VPN seguro desde Boston a El Salvador puede encontrar obstáculos técnicos o de políticas de seguridad interna de CEL.	Bajo	Iniciar conversaciones técnicas con el equipo de TI y seguridad de CEL desde el inicio de la Fase 0. Tener preparadas las alternativas (bastion host) para discusión.

Licencias y Dependencias de Código Abierto	El sistema se basará en Python y sus librerías. Se debe asegurar que todas las dependencias utilizadas tengan licencias de código abierto permisivas y compatibles con el uso de CEL.	Bajo	Mantener un registro de todas las librerías y sus licencias. Realizar una auditoría de licencias antes del despliegue final para garantizar el cumplimiento.
Soporte de TI interno de CEL	El sistema requerirá acompañamiento técnico interno para el despliegue y mantenimiento básico.	Medio	CEL designará un punto focal técnico para acompañar las fases de validación y operación (Fase 3 y 4), con al menos 20% de dedicación estimada.
Gestión de respaldo y monitoreo básico	El sistema deberá contar con respaldo regular de datos e infraestructura mínima de monitoreo para continuidad operativa.	Bajo	Se incluirá una rutina básica de respaldo local y alertas de ejecución automática en la documentación técnica (POE).
Escalabilidad e integración futura	La infraestructura del piloto se basa en una sola GPU. Una expansión de casos de uso requerirá más capacidad.	Nulo en piloto / Alto post-piloto	La arquitectura del sistema será diseñada de forma modular y documentada para facilitar escalamiento posterior (Fase III).

Estos aspectos no representan riesgos críticos para la ejecución del piloto, pero se presentan aquí para mantener la transparencia técnica del proyecto y asegurar la preparación institucional para una eventual escalabilidad de la solución.

Anexo Técnico E: Dinámicas Hidrológicas y Gobernanza Trinacional en la Cuenca del Río Lempa - Implicaciones para Modelos de Pronóstico con IA

1. Introducción

El Río Lempa constituye el sistema hidrológico más relevante de El Salvador y uno de los más complejos de Centroamérica. Su cuenca transfronteriza abarca 18,246 km², distribuidos entre Guatemala (12.6% o 2,295 km²), Honduras (31.2% o 5,696 km²) y El Salvador (56.2% o 10,255 km²)¹¹. Esta configuración geopolítica tiene implicaciones críticas para su gestión, ya que el

49% del territorio salvadoreño está cubierto por esta cuenca, albergando aproximadamente al 77.5% de su población, incluida la capital San Salvador¹¹. La implementación de un sistema de pronóstico hidrológico basado en inteligencia artificial debe considerar esta complejidad trinacional para lograr resultados efectivos ante los desafíos actuales y futuros que enfrenta la región.

2. Características Geográficas e Hidrológicas

2.1 Origen y Trayecto

El Río Lempa nace en la Sierra Madre de Guatemala a más de 2,800 metros sobre el nivel del mar, donde inicialmente se conoce como Río Olopa¹¹. Fluye por aproximadamente 30.4 km en Guatemala antes de entrar en Honduras, donde recorre 31.4 km adicionales¹¹. Al ingresar a El Salvador por Chalatenango, continúa su recorrido por 360 km hasta desembocar en el Océano Pacífico, completando un trayecto total de 422 km¹¹. Su caudal promedio es de 362 m³/s, medido en el puente Cuscatlán¹¹.

2.2 Zonificación Hidrológica

La cuenca presenta tres zonas hidrológicas distintivas, determinadas por su gradiente de elevación³:

- **Zona Alta (>1,500 m):** Caracterizada por suelos volcánicos (andosoles) con alta capacidad de infiltración (80-120 mm/hr) pero rápida saturación y escorrentía durante eventos pluviales intensos³.
- **Zona Media (500-1,500 m):** Funciona como área de transmisión hidrológica, donde la onda de crecida puede tardar hasta 7 días en desplazarse desde Guatemala hasta la frontera con El Salvador³.
- **Zona Baja (<500 m):** Comprende las planicies costeras, particularmente el Bajo Lempa, con capacidad de retención de inundaciones de hasta 72 horas, actuando como amortiguador natural ante eventos extremos³.

2.3 Puntos Críticos Hidrológicos

La geografía del río presenta singularidades que afectan su comportamiento hidráulico. La Garganta de Cuscatlán, con solo 300 metros de ancho, constituye un estrechamiento crítico que convierte hasta el 90% de la energía cinética aguas arriba en flujo turbulento durante las crecidas máximas³. Este fenómeno amplifica la energía del río y aumenta su potencial destructivo durante eventos extremos.

3. Riesgos e Impactos del Cambio Climático

3.1 Proyecciones Hidrológicas

Los modelos climáticos proyectan cambios significativos en el régimen hidrológico del Río Lempa para finales del siglo XXI¹³¹⁷¹⁹:

- Aumentos de temperatura de 1.9°C (escenario B1) a 3.4°C (escenario A2) para 2070-2099¹⁷¹⁹.
- Reducciones de precipitación del 5.0% (B1) al 10.4% (A2) para el mismo período¹⁷¹⁹.
- Disminución de caudales afluentes a los embalses del 13% (B1) al 24% (A2)¹³¹⁷¹⁹.

3.2 Estacionalidad y Eventos Extremos

Las mayores reducciones de caudal se proyectan durante junio a septiembre, coincidiendo con el inicio de la temporada lluviosa¹³. En julio, se anticipan disminuciones del 39% en el embalse Cerrón Grande y del 41% en el embalse 15 de Septiembre bajo el escenario A2¹³. Esta estacionalidad tiene implicaciones directas para la generación hidroeléctrica y la gestión de crecidas.

El evento de inundación de 2011 demostró las vulnerabilidades sistémicas cuando operadores de embalses liberaron aproximadamente 9,500 m³/s durante más de 12 horas, provocando el fallo de diques en la zona del Bajo Lempa¹. Este caso evidenció la necesidad de mejorar los sistemas de pronóstico y gestión entre represas y comunidades aguas abajo.

3.3 Dinámica de Sedimentos

La cuenca presenta una alta carga de sedimentos de origen volcánico, estimada en 28 millones de toneladas anuales³. El embalse Cerrón Grande intercepta aproximadamente el 78% de esta carga de fondo³, lo que acelera su colmatación y reduce su vida útil operativa. Este fenómeno compromete tanto la capacidad de generación eléctrica como la función reguladora de crecidas del sistema.

4. Gobernanza Trinacional

4.1 Marco Institucional

El Plan Trifinio, desarrollado como parte de los acuerdos de paz de Esquipulas de 1987, constituye la principal iniciativa de gobernanza transfronteriza para la gestión de la cuenca alta del Lempa¹⁵. Este plan representa una experiencia innovadora para Centroamérica,

demostrando voluntad política para institucionalizar la cooperación mediante un Tratado Internacional¹⁵.

4.2 Desafíos de Coordinación

A pesar de avances significativos, el Plan Trifinio evidencia limitaciones propias de enfoques descendentes (top-down) no acompañados por estrategias diseñadas por actores locales¹⁵. Esta desconexión dificulta la implementación efectiva de políticas integradas de gestión de recursos hídricos compartidos.

Persisten vacíos importantes en los protocolos operacionales transfronterizos, particularmente en la coordinación de liberaciones de agua durante eventos extremos y en el intercambio de datos hidrometeorológicos en tiempo real¹⁴. Este desfase entre decisiones aguas arriba y consecuencias aguas abajo representa un riesgo estructural para el sistema.

4.3 Iniciativas en Curso

Actualmente, el proyecto USAID Upper Lempa Watershed, implementado por Winrock International, trabaja con gobiernos, comunidades y grupos ambientales en la cuenca alta para mejorar su salud y resiliencia¹⁶. Este proyecto beneficia directamente a aproximadamente 180,000 personas en los tres países e incorpora aspectos de gestión integral del recurso hídrico.

5. Implicaciones para el Sistema de Pronóstico con IA

5.1 Desafíos de Datos Transfronterizos

La naturaleza trinacional de la cuenca presenta un reto fundamental para cualquier sistema de pronóstico: aproximadamente 65-70% del caudal del Lempa se origina fuera de las fronteras de El Salvador³. Esta realidad exige:

- Estrategias para compensar la limitada disponibilidad de datos en tiempo real en zonas fuera de la jurisdicción de CEL.
- Algoritmos que puedan operar eficazmente con fuentes de datos heterogéneas y de variable calidad.
- Capacidad para integrar datos satelitales y de sensores remotos para complementar las redes de monitoreo tradicionales.

5.2 Variabilidad Hidrológica Espacial

La pronunciada zonificación hidrológica de la cuenca requiere que el sistema de IA reconozca y modele adecuadamente:

- Las diferentes respuestas de escorrentía según el tipo de suelo y elevación.
- Los tiempos de viaje de onda de crecida a través de las distintas zonas (hasta 7 días desde Guatemala hasta la frontera salvadoreña).
- El efecto regulador natural de zonas como el Bajo Lempa con su capacidad de retención de 72 horas.

5.3 Enfoque de Modelado Adaptativo

Para abordar estos desafíos, el sistema de IA propuesto debe incorporar:

- Modelos LSTM (Long Short-Term Memory) capaces de aprender patrones temporales complejos en los datos hidrológicos.
- Enfoques de ensamble que combinen predicciones de múltiples modelos para mejorar la robustez.
- Integración de productos de teledetección como CHIRPS, ERA5, y misiones satelitales para compensar la limitada cobertura de estaciones de medición en tierra.
- Marcos probabilísticos que cuantifiquen y comuniquen la incertidumbre en los pronósticos, especialmente crítico en contextos transfronterizos.

6. Conclusión

La cuenca del Río Lempa presenta un escenario de alta complejidad donde convergen desafíos hidrológicos, ambientales e institucionales. Esta complejidad, sin embargo, también ofrece una oportunidad única para que CEL lidere la innovación regional en gestión hídrica inteligente.

El sistema de pronóstico hidrológico con IA propuesto representa no solo una herramienta tecnológica de vanguardia, sino un activo estratégico con potencial para transformar la gestión de recursos hídricos en Centroamérica. Al abordar específicamente la naturaleza transfronteriza de la cuenca y los retos del cambio climático, este sistema puede convertirse en un modelo replicable para cuencas compartidas en toda la región.

La posición única de CEL como administrador principal de la infraestructura hidroeléctrica del Río Lempa le confiere tanto la responsabilidad como la capacidad para implementar soluciones

innovadoras que equilibren la generación energética con la seguridad hídrica y la protección de ecosistemas y comunidades vulnerables.

Referencias

1. Comprehensive Analysis of the Río Lempa Basin: Transboundary Challenges and Opportunities 1
2. Flood Control Measures in the Río Lempa Basin 2
3. How does the Rio Lempa basin's geography influence its hydrological patterns 3
4. Río Lempa: Central America's Vital Transboundary Waterway 4
5. What are the main challenges in managing the Rio Lempa basin's hydropower network 5
6. Sistema Avanzado de Pronóstico Hidrológico 6
7. Central American Awareness Campaign to Rescue Lempa River 10
8. Lempa River - Wikipedia 11
9. Rio Lempa climate change impacts [13](#)
10. The Case of the Plan Trifinio for the Upper Lempa [15](#)
11. How USAID's Upper Lempa Watershed project supports transboundary water security [16](#)
12. Climate model based consensus on the hydrologic impacts of climate change [17](#) [19](#)

Citations:

1. https://ppl-ai-file-upload.s3.amazonaws.com/web/direct-files/attachments/11869384/70dc683d-9d42-495b-9042-89ef3eb5e9be/Comprehensive-Analysis-of-the-Rio-Lempa-Basin_-Tra-1.pdf
2. <https://ppl-ai-file-upload.s3.amazonaws.com/web/direct-files/attachments/11869384/423eefb3-a5bf-41ac-8b05-1a8e62d1648d/Flood-Control-Measures-in-the-Rio-Lempa-Basin.pdf>
3. <https://ppl-ai-file-upload.s3.amazonaws.com/web/direct-files/attachments/11869384/d0720af2-83c1-44f9-bb3a-3d33745f0b99/How-does-the-Rio-Lempa-basin-s-geography-influence.pdf>
4. <https://ppl-ai-file-upload.s3.amazonaws.com/web/direct-files/attachments/11869384/ac0ca7cd-af11-4bcc-b4b3-3fc8c48c5f2f/Rio-Lempa-Central-America-s-Vital-Transboundary-W-1.pdf>
5. <https://ppl-ai-file-upload.s3.amazonaws.com/web/direct-files/attachments/11869384/85c2d2cb-9f87-4a97-9282-50fd4450b75e/What-are-the-main-challenges-in-managing-the-Rio-L-1.pdf>
6. <https://ppl-ai-file-upload.s3.amazonaws.com/web/direct-files/attachments/11869384/f18a4207-ff38-4bfa-80f9-b23b12bdc962/paste-6.txt>
7. https://ppl-ai-file-upload.s3.amazonaws.com/web/direct-files/attachments/11869384/70dc683d-9d42-495b-9042-89ef3eb5e9be/Comprehensive-Analysis-of-the-Rio-Lempa-Basin_-Tra-1.pdf

8. <https://ppl-ai-file-upload.s3.amazonaws.com/web/direct-files/attachments/11869384/423eebf3-a5bf-41ac-8b05-1a8e62d1648d/Flood-Control-Measures-in-the-Rio-Lempa-Basin.pdf>
9. <https://ppl-ai-file-upload.s3.amazonaws.com/web/direct-files/attachments/11869384/d0720af2-83c1-44f9-bb3a-3d33745f0b99/How-does-the-Rio-Lempa-basin-s-geography-influence.pdf>
10. <https://ppl-ai-file-upload.s3.amazonaws.com/web/direct-files/attachments/11869384/ac0ca7cd-af11-4bcc-b4b3-3fc8c48c5f2f/Rio-Lempa-Central-America-s-Vital-Transboundary-W-1.pdf>
11. <https://ppl-ai-file-upload.s3.amazonaws.com/web/direct-files/attachments/11869384/85c2d2cb-9f87-4a97-9282-50fd4450b75e/What-are-the-main-challenges-in-managing-the-Rio-L-1.pdf>
12. <https://ppl-ai-file-upload.s3.amazonaws.com/web/direct-files/attachments/11869384/f18a4207-ff38-4bfa-80f9-b23b12bdc962/paste-6.txt>
13. <https://www.sei.org/projects/upper-lempa-river-basin-project-carl/>
14. <https://www.climatechange.org/news/seasonality-high-and-low-flows-of-the-worlds-largest-rivers-hardly-shifts-under-climate-change/>
15. https://en.wikipedia.org/wiki/2011_Missouri_River_Flood
16. <https://www.gwp.org/en/About/more/news/2021/central-american-awareness-campaign-to-rescue-lempa-river/>
17. https://en.wikipedia.org/wiki/Lempa_River
18. https://iahs.info/uploads/dms/1684816-71-76-346-29_Baozhong_Liu-H02Corr.pdf
19. <https://hess.copernicus.org/preprints/5/3099/2008/hessd-5-3099-2008.pdf>
20. <https://scholarcommons.scu.edu/cgi/viewcontent.cgi?article=1005&context=ceng>
21. https://iwrnactionhub.org/system/files/2021-11/Transboundary_Opportunities_and_Challenges_for_the_Shared_Management_of_Watersheds_the_Trifinio_Plan_for_the_Upper_Lempa_394.pdf
22. <https://winrock.org/how-usaids-upper-lempa-watershed-project-supports-transboundary-water-security-and-resilience-in-central-america/>
23. <https://hess.copernicus.org/articles/13/183/2009/>
24. <https://www.britannica.com/place/Lempa-River>
25. <https://scholarcommons.scu.edu/ceng/6/>
26. <https://humanright2water.org/human-rights-in-trifinio-region/>
27. https://www.iwra.org/congress/2008/resource/authors/abs578_article.pdf
28. https://en.wikipedia.org/wiki/2011_Mississippi_River_floods
29. <https://www.worldlandtrust.org/news/2025/04/protecting-access-to-clean-water-in-western-honduras/>
30. <https://hess.copernicus.org/preprints/5/3099/2008/hessd-5-3099-2008.pdf>
31. <https://www.elsalvadorperspectives.com/2011/10/flooding-of-lower-lempa-region.html>
32. <https://www.iadb.org/en/project/RG-T4189>
33. <https://scholarcommons.scu.edu/cgi/viewcontent.cgi?article=1005&context=ceng>
34. <https://www.youtube.com/watch?v=SkW3N29ypA>
35. <https://www.whiteclouds.com/blog/el-salvador-watershed-maps/>
36. <https://www.youtube.com/watch?v=GoUTffOI8c0>
37. <https://cig.uw.edu/publications/climate-model-based-consensus-on-the-hydrologic-impacts-of-climate-change-to-the-río-lempa-basin-of-central-america/>
38. <https://www.usgs.gov/publications/when-blue-green-waters-turn-red-historical-flooding-havas-creek-arizona>
39. <https://www.sciencedirect.com/science/article/pii/S0022169422013671>
40. <https://winrock.org/projects/usaids-upper-lempa-watershed-project/>
41. <https://www.wikidata.org/wiki/Q1511554>
42. <https://www.climatechange.org/news/seasonality-high-and-low-flows-of-the-worlds-largest-rivers-hardly-shifts-under-climate-change/>
43. <https://lca.logcluster.org/el-salvador-25-waterways-assessment>
44. <https://www.mdpi.com/2073-4441/12/2/507>
45. https://www.caf.com/traduccion/traduccion_en/debt-swap-for-the-lempa-river-a-milestone-and-model-for-the-world/
46. <https://lacgeo.com/lempa-river-central-america>
47. <https://www.sciencedirect.com/topics/earth-and-planetary-sciences/hydrological-regime>
48. https://transboundarywaters.ceoas.oregonstate.edu/sites/transboundarywaters.ceoas.oregonstate.edu/files/Database/ResearchProjects/HydropoliticalVul/hydropolitical_LA.pdf
49. https://www.waterboards.ca.gov/waterrights/water_issues/programs/bay_delta/california_waterfix/exhibits/docs/PCFFA&IGFR/PCFFA_71_Chung.pdf
50. https://tpwd.texas.gov/publications/pwdpubs/media/pwd_rp_t3200_2784.pdf
51. <https://colab.ws/articles/10.1088%2F1755-1315%2F925%2F1%2F012029>
52. <https://iwrnactionhub.org/case-study/transboundary-opportunities-and-challenges-shared-management-watersheds-trifinio-plan>
53. <https://voiceselsalvador.wordpress.com/tag/lower-lempa/page/3/>
54. <https://theclimatedatafactory.com/climate-projections/>
55. <https://www.resolutionmineeis.us/sites/default/files/references/fema-inflow-design-floods-dams-2013.pdf>
56. https://attains.epa.gov/attains-public/api/documents/actions/MDE_EASP/41094/108382
57. https://www.gwp.org/en/learn/KNOWLEDGE_RESOURCES/Case_Studies/Americas--Caribbean/Transboundary-Opportunities-and-Challenges-for-the-Shared-Management-of-Watersheds-the-Trifinio-Plan-for-the-Upper-Lempa-394/
58. <https://www.elsalvadorsolidarity.org/lower-lempa-mitigation/>
59. <https://www.mdpi.com/2073-4441/14/14/2242>
60. https://wmsrdoc.org/wp-content/uploads/2019/06/Sediment-TMDL-Ruddiman-Creek_GVSU_2013.pdf
61. <https://scor-int.org/Publications/WG116.pdf>

CAMILA CRUZ

DATA STRATEGY & AI CONSULTING

62. <https://www.whoj.edu/education/gsp/MCG/KOB1.pdf>
63. https://stormwater.pca.state.mn.us/index.php?title=Sediment_control_practices_-_Sediment_traps_and_basins
64. <https://www.power-technology.com/data-insights/power-plant-profile-cerron-grande-el-salvador/>
65. <https://library.oapen.org/bitstream/id/56e7e8e8-db55-4d28-b3d8-4d018dd2e6af/9789004528680.pdf>
66. <https://www.siteone.com/en/sc-st-sediment-trap/p/655153>
67. <https://imp.dayawisesa.com/wp-content/uploads/2024/03/Atlas.pdf>
68. <https://data.opendevlopmentmekong.net/dataset/71cbcc20-7167-4dbb-a565-fb5e4a6c4546/resource/7ad35bfa-8ae5-43be-93c1-f2329757c93f/download/qiz2014-0141en-river-basin-ecosystem-hydropower.pdf>
69. <https://www.ouranos.ca/sites/default/files/2024-02/Scientific-guidelines-to-facilitate-the-use--of-climate-projections.pdf>
70. [https://www.moa.gov.cy/moa/wdd/wdd.nsf/All/87B3408C013574D0C225820F002FE147/\\$file/1_4_1.pdf?OpenElement](https://www.moa.gov.cy/moa/wdd/wdd.nsf/All/87B3408C013574D0C225820F002FE147/$file/1_4_1.pdf?OpenElement)
71. <https://pubs.usgs.gov/wri/1986/4344/report.pdf>
72. https://iwr.mactionhub.org/system/files/2021-11/Transboundary_Opportunities_and_Challenges_for_the_Shared_Management_of_Watersheds_the_Trifino_Plan_for_the_Upper_Lempa_394.pdf
73. <https://hess.copernicus.org/articles/17/1/2013/hess-17-1-2013.pdf>
74. https://openiicareport.iica.go.jp/pdf/11406097_06.pdf
75. https://mde.maryland.gov/programs/Water/TMDL/DocLib_Conococheague_02140504/Conoco_Sed_TMDL_011609_Final.pdf
76. <https://www.science.org/doi/10.1126/science.aax1682>
77. <https://hess.copernicus.org/preprints/9/3339/2012/hessd-9-3339-2012-print.pdf>
78. https://en.wikipedia.org/wiki/Cerr%C3%B3n_Grande_Dam
79. <https://www.pca.state.mn.us/sites/default/files/c-s3-17e.pdf>
80. <https://www.stormwater.com/erosion-control/article/13036515/estimating-parameters-for-an-effective-sediment-basin-trap>